

分 类 号: TN911.73
研究生学号: 2017522024

单位代码: 10183
密 级: 公开



吉 林 大 学

硕士学位论文

(学术学位)

基于多特征融合的婴儿异常行为检测方法研究

Image-assisted discrimination method for
neurodevelopmental disorders in infants based on multi-feature fusion

作 者 姓 名: 戴晓辉

专 业: 信号与信息处理

研 究 方 向: 图像处理

指 导 教 师: 王世刚 教授

培 养 单 位: 通信工程学院

2020 年 05 月

基于多特征融合的婴儿异常行为检测方法研究

Image-assisted discrimination method for neurodevelopmental
disorders in infants based on multi-feature fusion

作者姓名：戴晓辉

专业名称：信号与信息处理

指导教师：王世刚 教授

学位类别：工学硕士

答辩日期：2020 年 05 月 29 日

吉林大学硕士学位论文原创性声明

本人郑重声明：所呈交学位论文，是本人在指导教师的指导下，独立进行研究工作所取得的成果。除文中已经注明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。本人完全意识到本声明的法律结果由本人承担。

学位论文作者签名：戴晓辉

日期：2020 年 05 月 22 日

关于学位论文使用授权的声明

本人完全了解吉林大学有关保留、使用学位论文的规定，同意吉林大学保留或向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅；本人授权吉林大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或其他复制手段保存论文和汇编本学位论文。

（保密论文在解密后应遵守此规定）

论文级别：☒ 硕士 ☐ 博士

学科专业：信号与信息处理

论文题目：基于多特征融合的婴儿异常行为检测方法研究

作者签名：戴晓辉

指导教师签名：王世刚

2020 年 05 月 22 日

摘 要

基于多特征融合的婴儿异常行为检测方法研究

一些由于不可测原因未达到足月便出生的婴儿，由于出生时的一些先天缺陷，产生脑性瘫痪、精神发育迟滞等严重的神经发育障碍的风险明显增高。神经发育结局异常的小婴儿早期在行为上表现为全身运动模式的异常，如在足月前及足月后 1 个月整体运动顺序缺乏变化性、单调，运动的幅度、速度和强度小。而在足月后 2 至 5 月龄观察不到遍布全身的各方向的小幅度中速运动，运动不流畅不协调。医生根据这些行为特点对小婴儿发育行为进行评判，并对评估异常的小婴儿给予早期干预，从而改善不良神经发育结局，这对治疗神经发育障碍性疾病，扭转其不良发育结局有很重要的意义。本文研究的目的是考虑是否可以用计算机视觉加机器学习的方法，代替传统人工判断，以提高效率。

首先，本文对婴儿的异常行为进行了分析，选择对婴儿进行目标跟踪，以观察其运动时的各项数据变化。分析传统的 **Meanshift** 跟踪算法后发现，该算法简单且非常适用于本文的单一背景样本视频，但考虑其判断的条件较为简单，在原有算法的基础上进行改进，提出基于注意力机制的关于婴儿的目标跟踪算法，以更加适应本文的视频样本的跟踪。弥补 **Meanshift** 算子存在的一些缺陷，并在婴儿样本的跟踪上取得了不错的跟踪效果。

其次，建立了关于婴儿多组特征的样本库。本文对于特征的提取，分别就基于运动轨迹的分析和基于人体特征的分析两方面进行了考虑，在考虑运动信号变化提取了基于运动轨迹的小波特征信息，基于运动轨迹的功率谱特征信息，在考虑婴儿运动过程中四肢运动的速度变化时提取了婴儿运动的速度特征信息，婴儿运动的加速度特征信息，以及婴儿的质心变化特征，在考虑基于人体特征情况下提取了婴儿质心数量特征。

最后，本文提出一种基于多特征融合的婴儿异常行为检测框架，首先对婴儿目标进行跟踪，然后进行多组特征的提取分析，对于特征进行自适应的融合判断，最后得出婴儿运动是否异常的结论。其中对于婴儿的检测过程中，传统对婴儿异常行为研究，往往将婴儿做为一个整体来研究，本文考虑将婴儿分为上，下，左，右四个肢体部分以及全身整体这一共五部分分别来研究，分别对这五个部分进行多组不同特征的提取和分类，最后结合它们进行综合的判断。对婴儿身体躯干分块判断，提高了对婴儿身体各个部位的灵敏度和特异度，也对最后的综合判断给出了更强有力的数据支撑。

关键词：

多特征融合，目标跟踪，神经发育障碍，行为识别，支持向量机

Abstract

Image-assisted discrimination method for neurodevelopmental disorders in infants based on multi-feature fusion

Premature infants have a significantly increased risk of developing severe neurodevelopmental disorders such as cerebral palsy and mental retardation due to some congenital defects at birth. Infants with abnormal neurodevelopmental outcomes behave early in behavior as abnormalities in whole body motor patterns, for example, before the full term and one month after the full term, the overall exercise sequence lacks variability and monotony, and the amplitude, speed and intensity of the exercise are small, while in the 2-5 months after the full term, small-scale moderate-speed movements in all directions throughout the body are not observed, and the movement is not smooth and uncoordinated. Based on these behavioral characteristics, doctors judge the developmental behavior of small infants and provide early intervention in small infants with abnormal assessments to improve adverse neurodevelopmental outcomes. This is very important for the treatment of neurodevelopmental disorders and to reverse their poor developmental outcomes. In this regard, we propose whether computer vision and machine learning can be used instead of human evaluation to improve the efficiency and accuracy.

Firstly, this article analyzes the specific manifestations of infants' abnormal behaviors, and tracks the infants to observe the changes in data during their movements. After analyzing the traditional Meanshift tracking algorithm, this algorithm is simple and very suitable for the single background sample video in this paper. However, considering the conditions for its judgment, a target tracking algorithm based on the attention mechanism is proposed, which is improved based on the original algorithm. To better suit the tracking of the video samples in this article. It makes up for some shortcomings of Meanshift operator and achieves good tracking results in tracking infant samples.

Secondly, sample databases of multiple groups of infants were established. For feature extraction, two aspects of analysis based on motion trajectory and analysis based on human characteristics were considered. Considering the change of the motion signal, the wavelet feature information based on the motion trajectory and the power spectrum feature information based on the motion trajectory were extracted. Considering the infant's movement, the speed feature information of the infant's movement, the acceleration feature information of the infant's movement, and the infant's centroid change feature were extracted. Considering the human body characteristics, the quantitative characteristics of the infant centroid was extracted.

Finally, this paper proposes a framework for detecting abnormal behaviors of infants based on multi-feature fusion. From tracking infant targets to extracting and analyzing multiple groups of features, and the results of the classification are comprehensively judged by data weighted fusion, so as to conclude whether the infant's neurodevelopment is normal and

whether early intervention is needed.

Among them, in the process of detecting infants, the traditional research on infants' abnormal behavior often studies the infant as a whole. This article considers dividing the infant into five parts: left hand, right hand, left lower limb, right lower limb and whole body. Study these five parts separately, feature extraction and classification, and finally make a comprehensive judgment. This improves the sensitivity and specificity of various parts of the infant's body, and also gives stronger data support for the final comprehensive judgment.

Keywords:

Multi-feature fusion, Target tracking, Neurodevelopmental disorders, Behavior recognition, Support vector machines

目 录

第 1 章 绪论.....	1
1.1 研究对象特点及研究意义.....	1
1.1.1 婴儿异常行为特点.....	1
1.1.2 婴儿异常行为的研究意义.....	1
1.2 国内外研究现状.....	2
1.3 本文的主要研究内容及安排.....	3
第 2 章 基于注意力机制的婴儿目标检测.....	5
2.1 基于图像的目标提取.....	5
2.1.1 图像噪声处理.....	5
2.1.2 图像特征提取.....	6
2.2 基于视频的目标跟踪.....	11
2.2.1 均值漂移算法（Meanshift）.....	12
2.2.2 核相关滤波算法（KCF）.....	13
2.3 基于注意力机制的目标跟踪.....	14
2.4 本章小结.....	16
第 3 章 婴儿运动特征提取.....	17
3.1 婴儿数据集介绍.....	17
3.2 小波变换分析轨迹信息.....	18
3.3 运动轨迹功率信息分析.....	19
3.4 婴儿运动速度加速度分析.....	20
3.4.1 婴儿运动速度特征.....	20
3.4.2 婴儿运动加速度特征.....	21
3.5 婴儿目标的质心分析.....	22
3.5.1 婴儿目标质心的个数.....	22
3.5.2 婴儿目标质心位置变化.....	24
3.6 本章小结.....	24

第 4 章 婴儿异常行为分析.....	26
4.1 基于多特征融合的婴儿异常行为判断框架.....	26
4.2 婴儿特征数据分析.....	27
4.2.1 特征降维.....	27
4.2.2 特征分析.....	30
4.3 基于多特征融合的婴儿异常行为分析.....	38
4.3.1 支持向量机算法.....	38
4.3.2 多特征融合及结果分析.....	40
4.4 本章小结.....	45
第 5 章 总结与展望.....	46
5.1 研究总结.....	46
5.2 研究展望.....	46
参考文献.....	48
作者简介及科研成果.....	53
致 谢.....	55

第1章 绪论

1.1 研究对象特点及研究意义

1.1.1 婴儿异常行为特点

婴儿异常行为主要是指出生五个月内,行动未见到遍布全身的加速度可变的各方向的小幅度中速运动,与年龄相适应的其他运动形式(如四肢中线运动、手膝相触、视觉搜索、手指抓弄衣服等)缺乏,整体运动流畅性欠佳。通俗的来讲,正常婴儿在出生五个月内四肢运动十分协调流畅,给人一种圆滑优美的感觉;相反,对于行为异常的婴儿,在其出生五个月内,四肢运动不协调,具有迟滞性僵硬感,其中有一些甚至不会翻身。婴儿的异常行为往往对应着脑部有损伤,严重者可能导致脑瘫的发生。由于脑瘫疾病通常在孩子一岁至两岁后才能确诊,因此,研究早期婴儿异常行为检测并及时进行干预治疗有很强的现实意义。

奥地利发育神经学家 Prechtl 教授于 1990 年首先提出在人类发育早期存在一种自发性的全身运动 (General Movements, GMs), 是最常出现和最复杂的一种自发性运动模式。该运动模式最早出现于妊娠 9 周的胎儿,持续至出生后 5~6 个月^[1]。该项指标能够有效地对早期的婴儿的神经发育进行评估。GMs 特征的具体表现为,对行为正常的婴儿,婴儿的四肢全部参与到运动中,运动给人的感觉很流畅,很灵活,但是相反的,对于行为异常的婴儿,婴儿运动的时候四肢并不协调,会有抽搐的感觉,其中一些婴儿在运动的时候,其运动的幅度,以及运动的速度都很夸张,人眼直观的感受就是婴儿的运动状态不受控制,别扭且僵硬。医学上现在多用全身运动 (GMs) 来对婴儿早期行为进行评估。

1.1.2 婴儿异常行为的研究意义

近年来,随着保健医学的发展,由于各种不可预测的原因导致的出生体重达不到标准甚至体重极低的早产儿的生存率有了明显提高。中国早产儿的发生率为 8.1%, 每年约有 180 万早产儿出生^[2]。随着围产期救治技术的进展,早产出生的婴儿,特别是早产不足月出生导致体重特别轻的婴儿的存活率得到了明显的提高。虽然大多数早产儿最终可以存活下来,但是伴随而来的一系列可能存在的并发症却不容乐观。据 NICHD 新生儿协作网报道,20 世纪 90 年代出生的胎龄为 27~32 周的早产儿神经发育损伤的发生率为 28%至 40%^[2]。伴随早产儿产生的有各种类型神经发育障碍,如智力低下,视觉、听觉障碍和轻微神经功能障碍等。这些并发症的存在可能性极大,就导致了虽然早产儿经过抢救最终存活,但是存活的质量并不高,由于相应症状的伴随使得之后的生活生存并不顺利。如果对这些潜在的疾病可以得到及早的发现,并且进行早期的干预,会对最后婴儿个体的发育产生良好的诱导结果。

据医学数据表明,位于脊髓上的神经中枢可能是产生 GMs 的神经结构。而妊娠 9 至 10 周之间 GMs 已经出现,在这段时间脑干以上的高级神经中枢还未发育完全,所以脑干以上的中枢结构不可能参与 GMs 的神经结构。研究表明,位于脑干的中枢模式发生器(CPG)是哺乳动物脊髓和脑干中的一种生理结构(或者叫神经元回路),能够产生行走、呼吸、咀嚼、啼哭等节律性运动^[3]。而奥地利发育神经学家 Prechtl 教授提出在人类胎儿和幼儿中有许多非节奏性运动模式(例如全身运动 GMs,惊吓,伸展,打哈欠)这些情况下生成神经机制也应该被称为 CPG。这些充分说明了婴儿肢体运动异常是婴儿脑神经生理学产生问题所表现出来的一种状态。婴儿的肢体运动行为异常与脑部神经发育状态息息相关。因此,通过判断早期的婴儿全身运动的状态是否异常,与判断婴儿的神经发育是否有问题有很强的关联性。这些均表明对婴儿的异常行为研究具有很强的现实意义和价值。

未足月出生的婴儿由于在母体中成长不足,容易导致身体机能发育不完全,脑组织发育尚未成熟,神经髓鞘未完全形成。而在刚出生的几年内,身体机能飞速发展,也是大脑发育的关键时刻,在这个期间,由于脑部神经发育问题而导致的婴儿的运动障碍处于初级阶段,还未形成固定的姿势,运动模式和运动状态。因此,在婴儿早期发育的关键时期,如果可以给予早期干预和早期治疗,可以修正婴儿的运动模式,缓解婴儿肌肉的紧张感和僵硬感,矫正并且改善婴儿的运动状态,也进一步对婴儿的脑部发育进行了良性的刺激,促进婴儿脑部的神经组织的良性发育,开发了脑部,同时也减轻和预防了一些与神经发育有关的疾病的发生^[4]。因此,医护人员在对早期的早产儿进行关于该个体的运动质量评估,不仅可以及时的发现运动欠缺有畸形的个体,同时还能进行及早的干预,通过干预引导和调整了婴儿大脑的发育,从而改善个体存活质量,有很重要的现实意义。

1.2 国内外研究现状

如今,未足月出生的婴儿最终成活的概率大大增加,但其往往伴随着多种可能存在的并发症,而其中关于神经发育的症状是可以通过婴儿的运动状态的异常与否来进行判断的。全身运动(GMs)质量评估是预测婴儿脑部的神经发育状态好坏的可靠评估工具,对婴儿有很高的特异性和敏感性。通过 GMs 的表现,可以预示患儿可能存在的缺陷,通过早期对 GMs 指标的评估识别,对婴儿进行早期干预,可以明显改善其预防。

目前已有的在结合运动识别上的研究中,主要的识别方式有间接传感器技术和直接传感器技术。

间接传感器设备,是一种间接依靠传感器且是集成的仪器设备,它往往和进行评估的环境融为一体,例如利用摄像机进行的视频分析的方法,Meinecke 等人^[5]使用七个摄像头,通过捕捉附着于新生儿身上的三维标记物对婴儿的运动进行分析,判断婴儿的运动是否异常。但是基于三维运动的捕捉系统及微软体感系统,操作复杂,比较昂贵,并不适于临床。Lars Adde 等人提出^[6]通过计算婴儿运动时的速度,加速度以及质心等参量进行建模对比,

从而对婴儿行为是否异常判断。Stahl A 等人^[7]提出利用光流法对视频中的婴儿进行目标跟踪，并对婴儿的运动结果进行分析。

基于直接传感技术的设备，是将硬件直接连接到受试者肢体，一般是指穿戴式的硬件仪器，如给予研究对象肢体佩戴加速度传感器或电磁追踪传感器等，这种情况适于四岁及以上儿童，对于婴儿而言，进行传感器设备穿戴后，往往会影响和干扰婴儿本身的运动，造成婴儿运动干扰和误判，因此直接传感技术设备对婴儿效果不明显，并不适合进行婴儿运动异常与否的判断。

对于不同的年龄阶段来说，神经系统处于不同的发育状态。因此要对某一年龄段的早产儿进行神经发育的诊断评估时，要有与该年龄段相契合的评估程序。而全身运动(GMs)的评估过程就考虑到了处于出生早期的婴儿年龄和该阶段婴儿所表现出的个体特性相适应的概念。医学研究表明，GMs 已广泛应用于临床，可准确预测高危儿的神经发育结局，准确率在 90%以上，具有非常良好的置信度。在临床上，对婴儿进行全身运动质量评估，往往需要经过培训有相关评估资格，且经验相对比较丰富的医生进行评判，然而医生在进行判断时有时也会偏主观性，而且重复性的判断完全可以用机器来代替，更加具有客观性并且能保持准确率，同时，还可以减少医护人员的重复的工作量，让医护人员处于一个高效工作的状态。对此，本文提出是否可以用计算机视觉结合机器学习的方式代替人工判断，提高检查的效率和准确度。

国内外提出一些关于结合机器学习的婴儿异常行为识别方法^{[7][8]}，这些方法指出婴儿的异常行为与婴儿的运动轨迹有关，脑部受损的婴儿相对于脑部正常的婴儿来说，其运动更混乱，可以说是无章可循，运动不流畅有停滞现象，而脑部未受损的婴儿在较低频谱的功率水平下表现出更高的平均功率。然而这些研究中并未提出可靠的评估框架，也未建立合理的特征样本库，这也是本文研究的出发点之一。

受神经发育的影响，GMs 对于正常婴儿和异常婴儿呈现出了不同且多样的表现形式，而本文研究是将临床观察到的这些运动形式用参数呈现出来，这个参数的高或者低体现了临床观察到的运动流畅或僵硬或加速度变化大小等，从而提示这些参数有改变的婴儿可能存在脑发育损伤或异常。所以在本文中，用 GMs 评估婴儿神经发育是否异常作为标准，试验对象的正常与否均由该标准得出，文章中所提出的方法的敏感性、特异性和准确性均与该标准判断出的指标进行对比。

1.3 本文的主要研究内容及安排

本文主要针对婴儿运动行为进行了研究，并在运动轨迹跟踪上提出了加入注意力机制的婴儿四肢目标跟踪算法，在特征的组合选取以及最后的特征融合方面提出了改进。包括以下内容：

- (1) 针对婴儿四肢目标跟踪现有的问题，提出加入注意力机制的目标跟踪算法。
- (2) 提取婴儿的运动信息，建立多个婴儿特征样本库，对多组特征进行最优选择，

得出最优的多特征组合。

(3) 分析多特征组合, 用支持向量机 (SVM) 进行正常与否的分类判断, 并提出自适应的多特征融合方法。

(4) 提出一种新基于多特征融合的婴儿异常行为判断框架, 并在各项指标上取得不错的结果。

本文一共分为 5 章:

第 1 章绪论, 介绍了本文研究背景及研究意义, 婴儿异常行为的特点和产生原因, 以及婴儿异常行为检测现阶段的发展状况, 并介绍了本文的研究内容及本文文章结构的总体安排。

第 2 章基于注意力机制的婴儿目标检测, 主要介绍了基于图像的目标提取, 基于视频的目标跟踪, 分析了这两类方式的优缺点, 提出了加入注意力机制的婴儿目标提取算法, 更加适用于本文的样本集, 分别对婴儿的左上肢, 右上肢, 左下肢, 右下肢以及全身进行目标跟踪, 为接下来的研究做铺垫。

第 3 章婴儿运动特征提取, 从基于婴儿运动时所呈现的运动轨迹分析和基于婴儿本身所具备的特征的分析两方面入手, 提取了关于婴儿的运动轨迹的小波域特征、功率谱域特征、婴儿运动的速度和加速度特征、婴儿质心的个数特征以及婴儿质心变化特征, 分别加以介绍和提取, 并对各类特征进行对比, 为下一步的多特征融合做准备。

第 4 章婴儿异常行为分析, 提出了一种基于多特征融合的婴儿异常行为分析的框架, 区别于传统的将婴儿视为整体分析, 分别对婴儿的左上肢, 右上肢, 左下肢, 右下肢以及全身五部分进行多特征的提取和建模; 在多特征融合阶段提出自适应的融合算法, 并利用 SVM 分类器进行婴儿行为是否异常的判断。

第 5 章总结与展望, 总结了本文的研究工作, 并对研究中仍存在的问题及后续工作给出建议。

第2章 基于注意力机制的婴儿目标检测

在对视频中的婴儿进行异常行为检测之前,首先要对视频中的婴儿个体进行特征的提取和运动的跟踪。这一操作往往被分为基于每一帧图像的特征提取分析和基于帧间信息的特征提取分析这两部分。对于图像的特征提取,常基于最基本的图像信息,提取图像中的各种特征如颜色,灰度,纹理等等。对于帧间信息的提取,是结合前后帧图像目标的信息,寻找不同帧之间的联系。针对不同的研究角度,本文将采用不同的特征提取方法对婴儿目标进行研究。

2.1 基于图像的目标提取

对于基于图像的目标提取,首先要做的是对含有目标婴儿的图像进行一系列的诸如去噪,平滑的预处理操作,填补图像不足之处,调节图像色彩,亮度等参数,以及对图像的均衡化处理。在进行完这一系列操作之后,对处理后的图像中目标进行特征的提取和分析。

2.1.1 图像噪声处理

首先基于图像信息对婴儿视频进行处理,具体而言,是将婴儿视频转化为一帧一帧的图像,并对每一帧图像中的目标婴儿进行基于图像本身的特征提取。对于转化后的帧图像中,由于拍摄的设备以及输出信道的原因,原视频中会掺杂随机信号,从而形成噪声。图像噪声往往会使图像产生离散,混乱的像素点,随着拍摄设备灵敏度设置的提高,捕获的信号越多,与此同时产生的误差也被放大,噪声从而变得可见,对目标的提取形成干扰。因此,对于获得的帧图像,首先要做的便是对图像噪声的处理。

对于图像噪声的处理,通常使用滤波的方式。图像滤波通常情况下并不会破坏太多的图像细节特征,同时还能够去除干扰图像特性的噪声。

图像滤波主要工作机理是规定一个邻域,对邻域范围内的像素按预定义的滤波器模板执行操作,用产生的新像素代替邻域中心点的像素,新像素的值就是执行滤波操作的结果值。滤波器依次访问图像中的每个像素点,就生成了处理后的图像。根据对像素执行的操作不同,滤波器的种类大致分为线性滤波器和非线性滤波器。图像滤波的基本公式如式(2.1)所示:

$$G(x,y)=\sum_{s=-a}^a\sum_{t=-b}^bw(s,t)f(x+s,y+t)\dots\dots\dots(2.1)$$

其中 w 为滤波器。

在去除噪声时,常用到平滑空间滤波器,其中有代表性的诸如线性均值滤波器,非线性

性中值滤波器，下面分别进行介绍。

(1) 均值滤波器

均值滤波器，顾名思义，该滤波器指定一个模板邻域，然后统计邻域内像素的值，再对邻域内的这些值进行平均操作，所得平均值即为输出，数学表达式如下所示：

$$G(x,y)=\frac{1}{M}\sum_{f\in S}f(x,y)\cdots\cdots\cdots(2.2)$$

其中， M 表示邻域像素的总个数。均值滤波器对于不同噪声的表现不同，该滤波方法对高斯噪声表现较好，但与此同时对椒盐噪声表现较差且对图像细节滤波效果一般。

(2) 中值滤波器

中值滤波器，是通过统计模板区域中的像素值的中值进行滤波操作，输出的是该邻域内的所有像素的中值。它的数学表达式见式(2.3)所示：

$$G(x,y)=\underset{x,y\in S}{\text{median}}\{f(x,y)\}\cdots\cdots\cdots(2.3)$$

从总体上来讲，中值滤波对噪声的消除效果比较好，图像的一些细节以及图像的清晰度也都可以保持，但与此同时它也有一定的缺点，那就是高斯噪声不敏感。本文根据实际图像的表现，选取了中值滤波除噪。

2.1.2 图像特征提取

对于图像进行预处理后，便可进行下一步关于婴儿图像特征的提取。根据性质的不同大致有颜色直方图，梯度特征，边缘特征，多尺度特征，纹理特征这些图像特征提取方式，针对这些特征，下面将分别予以说明。

(1) 颜色直方图特征

颜色特征是计算机视觉中最直观，最重要的特征之一，在外部环境变化的情况下也能保持稳定，即具有鲁棒性。常见的颜色模型大致分为 RGB 颜色模型，HSV 颜色模型，CMYK 颜色模型。本质上来讲，彩色模型就是坐标系统和子空间的描述说明。

在 RGB 模型中，红，绿，蓝这三种颜色是组成光谱的原色，在模型中存在的其它每一种颜色都由这三种颜色组合而成。在该模型下的图像，都是三种维度合成的图像，它们分别由这三个原色组成三幅包含不同原色分量的图。当送入 RGB 模型中时，这三维的图像再组合在一起，从而形成彩色图像。在 RGB 空间中，定义了像素深度，即每个像素的比特数。规定一幅 RGB 图像中的三个通道图像，即红，绿，蓝，它们都是 8bit 图像。这样每一幅 RGB 图像都是 24bit 的深度，进一步可得到颜色总数是 $2^{24}=16777216$ 。因为 RGB 模型下的彩色图像蕴含了丰富的色彩信息，它的颜色可细分至上千万种，要提取并且对这些丰富的色彩信息加以利用，就可以统计其直方图，这样便可以得到不同颜色在图像中的分布状况。要统计含有婴儿目标图像的颜色直方图，首先要对含有婴儿目标的图像进行颜色量化。采用分开区间分别进行统计的方法，将其分成多个区间，每个小区间成为直方图的一个归类区域。然后，直方图便是通过计算婴儿图像中不同的颜色落在每个区域内的像

素数量得到的。本文对含有目标婴儿的图像进行了颜色直方图的提取，如图 2.1 所示为目标婴儿以及该婴儿的 RGB 颜色直方图，从图中可以看出该图像中 R，G，B 这三个颜色分量的直方图统计情况。

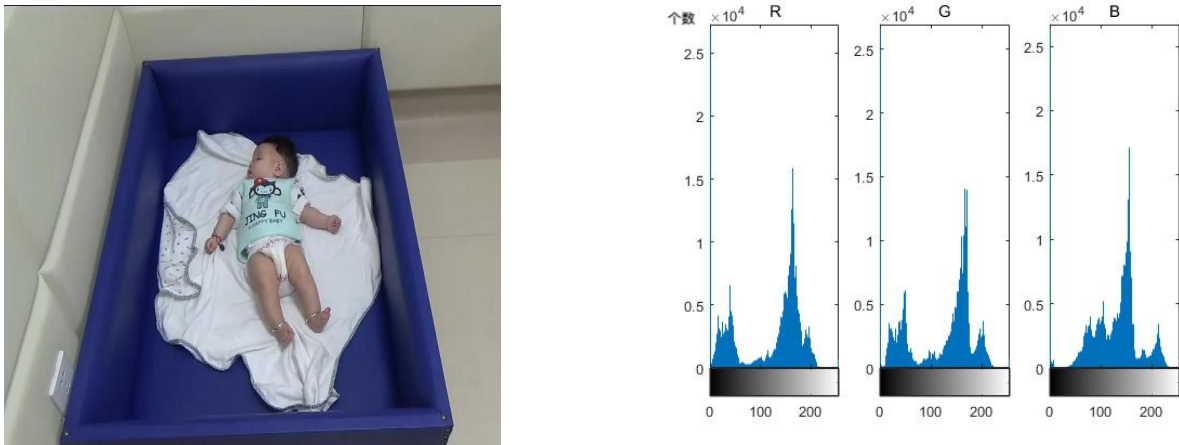


图 2.1 婴儿及 RGB 颜色直方图

(2) 梯度特征

图像梯度主要是针对图像中目标的边缘信息进行的一种特征提取，利用图像中的梯度变化研究像素变化规律，从而实现目标检测及定位。其中方向梯度直方图（HOG）特征通过计算图像中每一部分区域的梯度方向的分布情况，统计其直方图来构成特征，是进行目标检测常用特征描述子。

HOG 特征的提取过程简单的来说，首先将图像进行灰度化处理。由于灰度化后的图像，它的颜色值在某些位置可能差异很大，为了方便处理，再对其进行归一化，这样处理后的图像的对比度降低，当由于光照所造成曝光过度或者有阴影时，对比度的降低会使这些因素造成的影响也降低。然后便是根据其定义统计像素的梯度大小及方向，这样可以有效的得到目标婴儿的轮廓信息。再将图像划分成许多个小块，统计每个小块里不同梯度的个数。统计完毕后构成该模块的梯度直方图，即可形成关于每个图像小块的特征描述器。最后将小块组成大的分块，再将大分块特征描述器全部都合并在一起进行统计比较，便得到该目标婴儿的 HOG 特征描述器。如图 2.2 所示即为图像提取 HOG 梯度特征的简单流程图。这个描述器就是最后可以用来做为分类依据的关于婴儿的特征向量。

在本文中，对包含目标婴儿的视频图像进行 HOG 特征的提取，如图 2.3 所示为单帧婴儿图像及该图像提取到的 HOG 特征。根据 HOG 特征，可以对目标婴儿的轮廓进行描述，从而提取出目标婴儿的边缘变化信息。

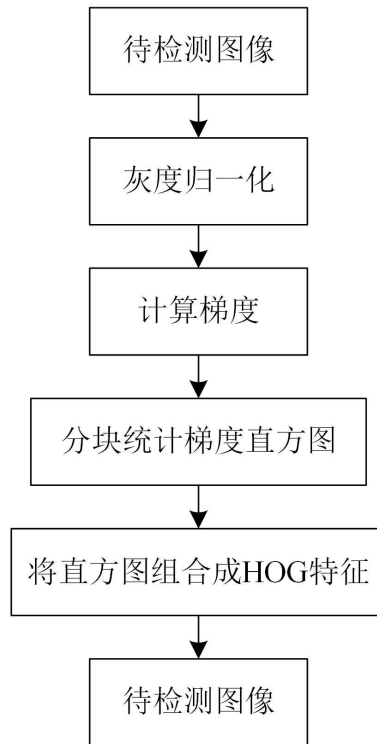


图 2.2 图像 HOG 特征提取流程图




图 2.3 婴儿及 HOG 特征图

(3) 多尺度特征

图像的多尺度特征，也是一个经常用来分析的特征。所谓的多尺度特征，就是建立多个不同尺度坐标系对同一目标图像进行分析。这样一幅图像放在不同的尺度下，会有不同的信息特征表述，这些信息特征有相同的，也有不同的关键点，将其中相同的关键点进行匹配，所提取出的就是不论尺度如何变化，自身都不会变的特性，即尺度不变性。通过对多尺度的图像特征分析，可以得到对目标图像的综合的理解和应用。对于多尺度空间，其实质就是寻找合适的核函数，利用核函数可以产生不同的关于尺度的描述，对于一幅二维图像，它的的多尺度空间可表示为：

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y) \cdots \cdots \cdots (2.4)$$

其中 $I(x, y)$ 为原始图像, x, y 为坐标, σ 为尺度参数, G 为核函数。

图像的多尺度几何分析方法分为自适应的分析方法和非自适应的分析方法两类。所谓自适应方法是在检测图像目标的过程中通过自动调节寻找最优表示, 此类方法以 **Bandelet** 和 **Wdget** 为代表, 放在本文中即先对目标婴儿进行边缘检测, 然后利用检测的边缘信息, 寻找可以最优的函数表示。非自适应的方法, 其代表为 **Ridgelet**、**Curvelet** 和 **Contourlet** 变换, 是在进行分析时并不需要知道该图像的几何特征, 直接对图像进行分析, 即直接对目标婴儿放到固定的框架中分解, 该方法对于先验知识依赖的比较少, 是通过分解的过程中不断的提取特征信息。由于本文是要提取图像中目标的特征, 不需要先验知道图像本身的几何特征, 直接对整幅图像进行多尺度分析便可得到目标边缘, 因此选用的是非自适应的 **Contourlet** 变换。

Contourlet 变换利用的是它灵活的多尺度以及多方向的特性。它由拉普拉斯塔形分解 (LP) 和方向滤波器组 (DFB) 组成。**Contourlet** 变换的独到之处是它将多尺度的计算和多方向的计算分成了两部分分别进行。首先由 LP 对图像进行多尺度分解, 在这个过程中可以得到一系列的奇异点, 然后由 DBF 将分布在同一方向上的被求出的奇异点, 合成一个系数。根据其分解的原理, 在 **Contourlet** 系数中, 越是表示图像的边缘, 它的系数能量越集中。

在具体操作中, 基于图像平移不变性的考虑, 本文加入了非下采样的处理方法。首先由非下采样金字塔 (NSP) 对输入的目标婴儿图像进行多尺度的分解, 这样可将婴儿图像分为高通, 低通两个部分。然后对于高通的部分, 用非下采样方向滤波器组 (NSDFB) 将其分解成为关于多个方向的子带。对于低通的部分, 则继续进行如上分解。由此可以得到各层的 **Contourlet** 系数。如图 2.4 为图像进行 **Contourlet** 分解的系数表示子图。




图 2.4 **Contourlet** 系数分解图

(4) 纹理特征

图像的纹理特征, 是一种反映图像中同质现象的视觉特征。它体现了物体表面的具有缓慢变化或者周期性变化的表面组织结构排列属性。不同于梯度, 颜色等特征基于图像素点本身来研究, 纹理是结合了像素以及该像素点周围邻域的灰度分布形成局部纹理特征

来进行研究的。该特征不仅包含了自身像素的特征，还包含了与周围像素的相关性特征。

在提取纹理特征时，较为常用的是局部二值模式(LBP)算子，它具有旋转不变性和灰度不变性的特质。

LBP 的基本思想就是对于目标像素周围的邻域内的像素值进行一个统计，比目标像素大的记为 1，比目标像素小的记为 0，以此编码，并转化为二进制数字，该数字就表示该像素区域的纹理特征，然后统计整幅图中的数字分布，即可得到整幅图的纹理特征。以 3×3 的区域为例，如下图 2.5 所示，从左下角开始，沿逆时针方向依次与中心像素进行比较，如果大于等于中心像素的取值为 1，否则为 0。得到一个 01 序列，将其视为一个二进制数。再将二进制数转化为十进制数即可。



图 2.5 LBP 原理图

在本文的对目标婴儿图像进行实际处理时，为参考提取多方向样本点，采用了圆形的 LBP 算子，将一个圆分成若干个扇形区域，对每个区域的像素值进行计算，从而编码得到 LBP 特征值，其中设置采样点数为 12 个，圆域半径为 2.5。

利用该算子对含有目标婴儿的图像进行 LBP 特征的提取，如图 2.6 所示为目标婴儿的原图和婴儿的 LBP 特征以及根据 LBP 特征得到的 LBP 特征直方图。从图中可以看出含有目标婴儿的视频图像的 LBP 特征很好的反映出了图像的纹理特性，突出了目标婴儿的轮廓和边界。对能够反映目标婴儿的轮廓和边界的 LBP 特征进行直方图统计，便记录下了整幅包含目标婴儿图像的纹理特征的分布和变化情况。通过该直方图，可以在对目标婴儿的跟踪过程中起到区分目标婴儿和背景的作用，成为一项可行的判断是否为目标婴儿的条件。

通过介绍上述几种对含有目标婴儿的图像特征提取方法，本文中所研究的婴儿视频都进行了相应的特征提取并进行分析。其中颜色特征和 LBP 特征对于区分目标婴儿和背景板都有很好的特异性，多尺度特征和梯度特征也均有不错的性能表现，多尺度特征方法单独用来判断时具有很好的性能，但如果想要用来和其它方法结合时，复杂度是一个要考虑的因素。

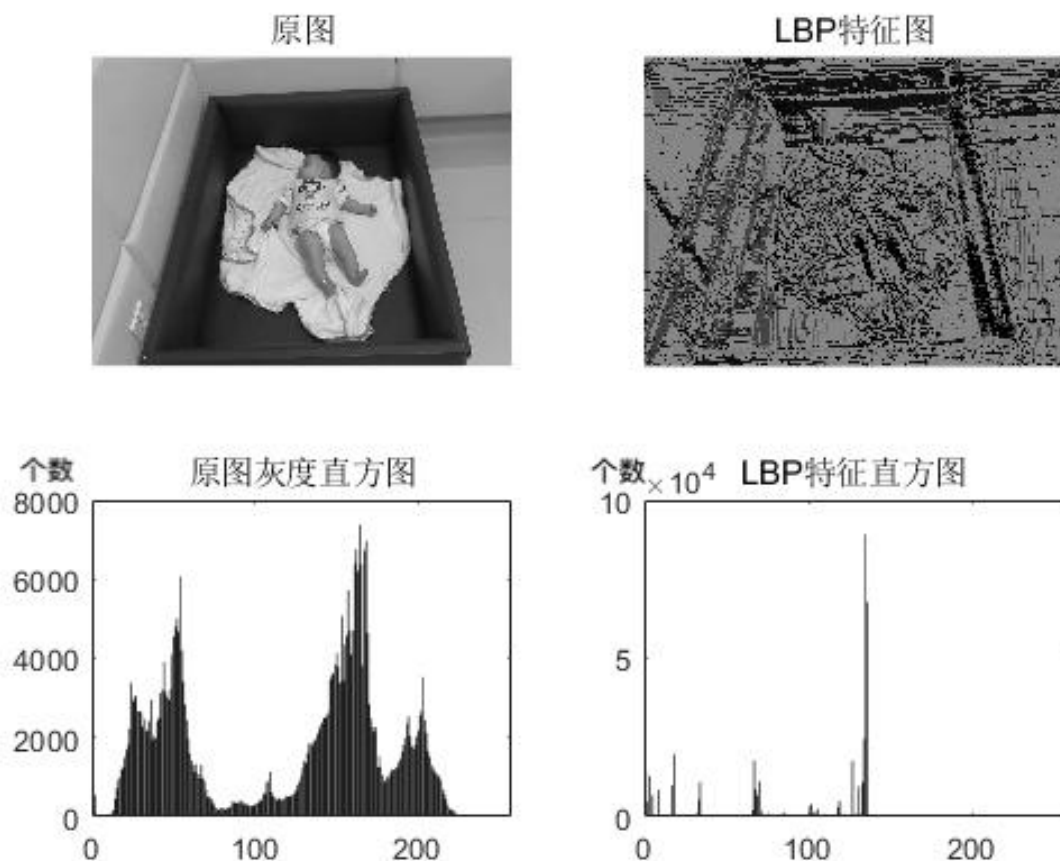


图 2.6 婴儿 LBP 特征图

2.2 基于视频的目标跟踪

基于视频的目标跟踪，根据跟踪方法的建模原理方式不同，大致可分为生成 (generative) 模型方法以及判别 (discriminative) 模型方法。所谓的生成类方法，是对图像的当前帧选取一个目标位置区域，然后建模，确定一个关于相似性度量的准则，跟踪的过程也是寻找最优相似度的过程，即在每次下一帧中都去寻找与所建立的模板最相似的图像的位置区域，该区域即为跟踪的目标区域。比较著名的有卡尔曼滤波，Meanshift 等。举个例子，假设当前帧中的目标位置 70% 是蓝色，30% 为黄色，那么在接下来的跟踪过程中，就搜索最符合这个颜色比例的区域。对于判别类的方法，该方法一般是图像的特征以及机器学习方法的组合。根据提取到的图像特征建立样本集，然后训练分类器去自动的寻找最优的目标跟踪区域，该方法的优点是如果样本集足够的大，那么准确率很高，但同时样本集的构建好坏也是一个关键的问题。接下来，在这两类跟踪方法中，本文分别选取了其中具有代表性的方法，进行分析比较其特性。

2.2.1 均值漂移算法 (Meanshift)

Meanshift 算子，是一个迭代的过程，选取一个合适的核函数，计算出当前视频帧中跟踪的目标位置的偏移均值，以此为起点在视频帧中继续移动，直到满足小于规定阈值或迭代次数的条件便停止移动。对于该目标跟踪算法的实现，首先计算目标区域关于该区域的像素的特征概率直方图，再计算候选区域的像素的特征概率直方图。然后选用合适的相似度量函数，用来度量目标以及候选这二者相似性。最终使得相似函数取得最大值的候选目标，作为跟踪到的新目标，即看作一个新的起点继续进行判断度量跟踪过程，最初的目标位置到寻找到的新起点之间便是一个重要的向量指标，该向量被称为 Meanshift 向量。这个向量也正是目标由初始位置向正确位置移动的向量。通过不断的满足一定条件的迭代计算，算法最终将收敛，而最后收敛的位置，便被认定是下一帧中跟踪到的目标位置。

Meanshift 算子的具体跟踪步骤如下：

(1) Meanshift 算子的核函数

其用到的核函数为 Epannechnikov 核函数，它的定义如下：

$$K_E(x) = \begin{cases} c(1 - \|x\|^2), & \|x\| < 1 \\ 0, & \text{else} \end{cases} \quad \dots\dots\dots (2.5)$$

(2) 目标模型的描述

对于目标模型的描述，首先人工标定要跟踪的目标位置，然后统计目标位置的颜色灰度直方图。具体操作如下：假设目标位置中有 n 个像素，用 $\{z_i\}_{i=1\dots n}$ 表示，对选中的目标区域中的灰度颜色空间进行一个均匀的划分，便可以得到一个灰度直方图，这个直方图有 m 个相等的区间。目标模型 q_u 的概率密度 ($u=1, \dots, m$) 可表示为：

$$q_u = C \sum_{i=1}^n K\left(\|z_i^*\|^2\right) \delta[b(z_i) - u] \quad \dots\dots\dots (2.6)$$

$$C = 1 / \sum_{i=1}^n K\left(\|z_i^*\|^2\right) \quad \dots\dots\dots (2.7)$$

$$z_i^* = \left(\frac{(x_i - x_0)^2 + (y_i - y_0)^2}{x_0^2 + y_0^2} \right)^{0.5} \quad \dots\dots\dots (2.8)$$

其中， z_i^* 表示归一化之后目标区域中的像素所在的位置。 (x_0, y_0) 为目标中心坐标。 K 是核函数，本文所用的为 Epannechnikov 核函数。 $b(z_i)$ 用来表示 z_i 处像素属于哪个直方图区间。 u 是一个关于颜色直方图的颜色索引。由此知 $\delta[b(z_i) - u]$ 函数的作用是判断目标区域中像素 z_i 处的灰度值是否属于直方图中第 u 个单元，等于为 1，否则为 0。 C 是归一化系数。

(3) 候选模型的描述

对候选模型，以前一帧的目标中心为中心去搜索，统计候选位置的颜色灰度直方图，该区域的像素用 $\{z_i\}_{i=1\dots n}$ 表示。具体统计操作如下：

$$p_u(f) = C \sum_{i=1}^n K \left(\left\| \frac{f - z_i}{h} \right\|^2 \right) \delta[b(z_i) - u] \cdots \cdots (2.9)$$

h 为决定权值大小的核函数窗口。候选目标的中心位置坐标为 f 。其他参数和公式 (2.6), (2.7), (2.8) 的定义相同。

(4) 相似度量

相似度量时, 需要用到相似函数进行判断, 即对于在目标跟踪过程中设定好的目标模型和候选模型之间, 用一个具有相似判断能力的函数对两个模型进行相似性判断。

该算子采用 Bhattacharyya 系数作为相似函数, 函数的定义为:

$$\rho(p, q) = \sum_{u=1}^m \sqrt{p_u(f) * q_u} \cdots \cdots (2.10)$$

如果使该相似函数的值越大, 则说明要比较的两个模型越是相似。使得该相似度最大的区域便是本帧的目标区域。

(5) 目标跟踪过程

整个的目标跟踪的过程, 就是不断寻找使相似函数最大的位置。对相似函数进行泰勒展开, 得到一个近似的表达:

$$\rho(p, q) \approx \frac{1}{2} \sum_{u=1}^m \sqrt{p_u(f) * q_u} + \frac{C}{2} \sum_{i=1}^n w_i K \left(\left\| \frac{f - z_i}{h} \right\|^2 \right) \cdots \cdots (2.11)$$

$$w_i = \sum_{u=1}^m \sqrt{\frac{q_u}{p_u(f)}} \delta[b(z_i) - u] \cdots \cdots (2.12)$$

极大化过程可以通过候选中心向真实区域中心的 Meanshift 迭代方程完成:

$$f_{k+1} = f_k + \frac{\sum_{i=1}^n w_i (f_k - z_i) g \left(\left\| \frac{f_k - z_i}{h} \right\|^2 \right)}{\sum_{i=1}^n w_i g \left(\left\| \frac{f_k - z_i}{h} \right\|^2 \right)} \cdots \cdots (2.13)$$

其中, $g(x) = -K'(x)$ 。Meanshift 方法就是不断的对比两个模型, 然后朝着使相似函数变化最大的方向一直移动, 直到两次移动距离小于阈值便停止。这个时候所在的位置便是该算子认定的目标位置。然后更新目标位置模板, 以它为新起点继续搜索。

2.2.2 核相关滤波算法 (KCF)

核相关滤波算法属于判别类的跟踪算法。一般衡量信号之间是否相似, 相似的程度, 会用到相关这个概念, 如果两个信号相似的程度很高, 相关系数也高。而对于 KCF, 就是用到一个滤波模板, 当它进行跟踪的时候, 只有在目标位置, 响应最大。为了训练判别器, 所需要的样本是利用循环矩阵在原图上产生的。

设训练样本为 (x_i, y_i) , 其线性回归函数为:

$$f(x_i) = w^T \cdot x_i \cdots \cdots (2.14)$$

其中 w 表示权重系数。KCF 的误差函数为

$$\min_w \sum_i (f(x_i) - y_i)^2 + \lambda \|w\|^2 \dots \dots \dots (2.15)$$

最终训练的目的是找一个合适的函数 $f(x_i)$ ，使得误差函数最小。

2.3 基于注意力机制的目标跟踪

很多现有的目标跟踪算法往往基于单一的核函数或者是较为单一的图像特征进行跟踪判断，由于条件单一从而导致跟踪存在缺陷。对于 **Meanshift** 算法，它的判断条件简单，主要是基于颜色特征直方图，计算量小，这样的话基本可以实现实时跟踪，而且对边缘遮挡、目标旋转、变形和背景运动不敏感。但是其也存在一定的缺点，如下所示：

- (1) 模板是固定的，没有更新的过程，在跟踪过程中一旦目标的大小有了明显的变化，跟踪就失败；
- (2) 当目标运动的比较快的时候，跟踪效果并不是很好；
- (3) 由于选取的特征只有颜色直方图，虽然简单易提取，但是相比蕴含丰富特征的目标来说略显匮乏，缺少信息描述。

针对这些问题，本文设计了一种改进的基于注意力机制的目标跟踪算法。该方法在原有的跟踪中加入注意力机制，以此来修正跟踪路径。

改进的目标跟踪算法，首先对单帧的含有目标婴儿的图像提取信息，将图像分成多个小块，提取颜色特征和纹理特征。然后统计每小块的颜色直方图，同时也统计 **LBP** 特征统计直方图。这样对于每小块都可以用颜色直方图和 **LBP** 特征的统计直方图来进行描述。用 **Meanshift** 算子分别对婴儿的左上肢，右上肢，左下肢，右下肢以及全身整体进行目标跟踪，在 **Meanshift** 算法中进行目标位置判断时，引入注意力机制，即用单帧图像得到的信息对跟踪的位置做修正，从而改善跟踪效果。

具体操作步骤如下：

- (1) 输入图像，图像预处理，去除噪声；
- (2) 将图像划分成多个小块，分别提取 **LBP** 特征，并统计 **LBP** 特征直方图；
- (3) 输入视频，对视频用 **Meanshift** 算子进行跟踪，利用核函数对于目标位置建模归一化后得到目标的颜色模型；
- (4) 统计当前帧的候选模型颜色直方图，同样利用核函数对候选模型建模；
- (5) 对目标区域和候选区域进行相似性度量，在这里引入基于图像特性的修正，计算分块的 **LBP** 特征直方图，为其自适应的设置权重，修正度量精度；
- (6) 根据相似函数更新目标的坐标；
- (7) 更新坐标直到移动距离小于所规定的阈值，这个时候便认为找到目标位置，以此作为新起点继续搜索，重复上述步骤。

改进的基于注意力机制的目标跟踪算法流程图如图 2.7 所示：

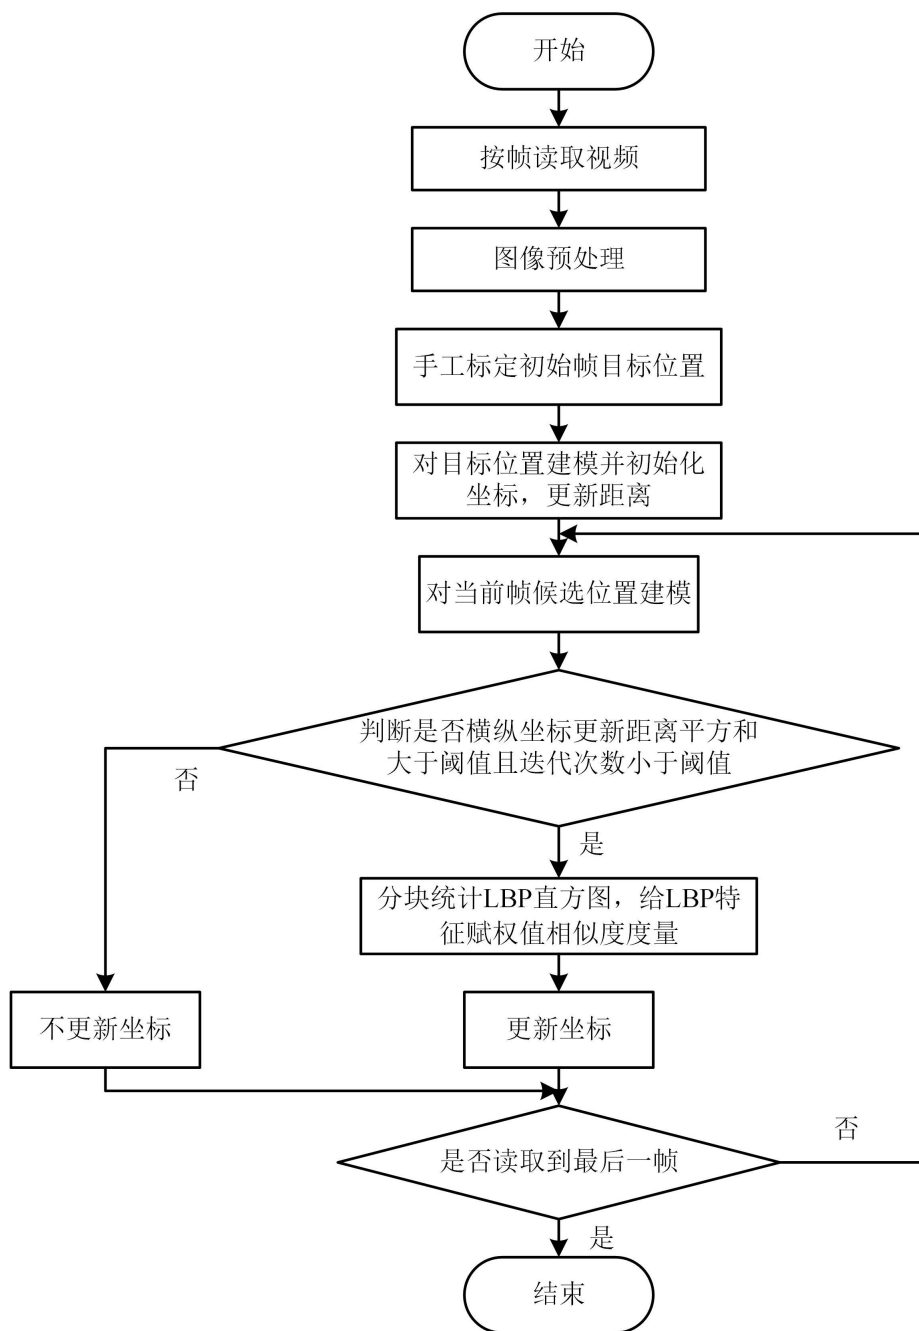


图 2.7 基于注意力机制的目标跟踪算法流程图

将含有目标婴儿的视频送入基于注意力机制的目标跟踪算法框架中进行对婴儿四肢及全身的目标跟踪, 并分析结果。

如图 2.8 所示是 Meanshift 算子跟踪和本文基于注意力机制修正的目标跟踪对比, 在对比过程中随机选取了第 10, 15, 21, 25, 30 帧视频画面进行对比, 其中第一行为基于注意力机制的目标跟踪, 第二行为 Meanshift 算子的跟踪结果, 从这两组跟踪视频的对比结果

中可以看出,随着不断的迭代跟踪,基于注意力机制的婴儿目标跟踪抗干扰的效果更好一些,基本上不会框丢或者框歪目标位置。但是基于注意力机制的婴儿目标跟踪计算复杂度要高于 **Meanshift** 算子,可以说本文是在牺牲了一定时间的情况下换取了更好的跟踪效果,然而由于本文所研究内容是对婴儿异常行为的判断,并不要求实时性,所以从准确度和抗干扰能力这两个角度考虑,选择使用虽然不能达到实时但是跟踪效果要更加的基于注意力机制的目标跟踪方法。



图 2.8 目标跟踪算法对比图

2.4 本章小结

本章介绍了图像预处理中去噪的方法,基于图像的目标提取方法以及基于视频的目标跟踪方法。其中基于图像的目标提取方法大致有颜色特征提取,梯度特征提取,纹理特征提取以及多尺度特征提取;基于视频的目标跟踪,选取了两个跟踪算子,分析了它们的跟踪的优缺点及产生缺点的原因,针对这些缺点,本文提出了基于注意力机制的目标跟踪框架,对视频中的目标婴儿进行跟踪,为下一步的关于目标婴儿的特征提取和特征的分析做了铺垫。

第3章 婴儿运动特征提取


本文所研究的内容是针对出生五个月以内婴儿异常行为的检测,对于异常行为,由于表现突发,也没有周期性可寻,而且在定义的过程中并没有可依赖的样本库,因此,特征选择好坏直接关系到最终模型的准确度高低。

对于异常行为分析,常用的方法分为基于运动轨迹的分析和基于人体特征的分析^[9]。其中基于运动轨迹的分析,就是根据所得的轨迹提取特征并加以分析,运动轨迹中往往蕴含着丰富的时空信息以及运动间相关联的信息。对运动轨迹中的信息进行提取并分析,通常可以得到具有特异性的特征从而进行分类。基于人体特征的分析,是指对目标本身的特征的提取,如目标的质心变化,轮廓变化等,提取基于人体本质的特征,与实际人体表现出的行为之前有很强的关联性。对人体蕴含的特征进行提取并分类,也可用于最终类别的区分。在研究中针对这两种分析方法分别提取多组特征,可以同时兼顾目标所蕴含的时空信息和本质信息。因此本章针对婴儿本身以及第2章得到的婴儿四肢运动轨迹,进行特征提取,提取多组特征,并对这几组特征进行分析和对比,最终选择表现较优的几组特征进行分类比较。

3.1 婴儿数据集介绍

在本文研究试验中所用到的小婴儿视频均为医院提供的真实数据,由数码摄像拍摄。记录时使所观察的婴儿对象处于仰卧的状态,并且放在暖箱或垫子上。婴儿的四肢均保持裸露状态。保持婴儿活动觉醒状态,避免在哭闹、烦躁、持续打嗝或使用安慰奶嘴时记录所得,从而保证婴儿的运动均出于自然状态的本能动作。本文实验中选取的婴儿样本共计120个,其中60个为行为正常的婴儿,60个为行为异常的婴儿,年龄均为10至20周之间。

首先对数据集中婴儿的四肢及全身进行目标跟踪,保存为x轴下的运动轨迹以及y轴下的运动轨迹,如图3.1所示,左图(a)为目标在x轴下的运动轨迹,右图(b)为目标在y轴下的运动轨迹。由于婴儿在x轴下的运动轨迹差异不大^[7],因此以下的研究中都针对在y轴下的运动轨迹进行。对婴儿的运动轨迹所含有的信息,本文分为婴儿运动轨迹的小波域特征和婴儿运动轨迹的功率谱特征两部分分别进行信息的提取;对于婴儿运动时的状态,本文分为婴儿运动的速度特征和婴儿运动时的加速度特征分别进行信息的提取;同时对于婴儿本身在不同时刻位置的不同,本文分别提取婴儿的质心变化特征和婴儿的质心个数特征。接下来是对这些不同特征的提取的一个详细描述。



(a) x 轴下运动轨迹

(b) y 轴下运动轨迹

图 3.1 坐标轴下的运动轨迹

3.2 小波变换分析轨迹信息

对于第 2 章我们已经提取到的婴儿左上肢, 右上肢, 左下肢, 右下肢以及全身五部分的运动轨迹进行分析, 由于已经得到的 y 轴运动轨迹波形图是非平稳的信号, 为进一步抽象出波形中所含的信息, 考虑采用频谱变换中的小波变换方式。小波变换能够同时兼顾到频率信息以及信号时间信息, 其公式如下:

$$WT(a, \tau) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} f(t) * \phi\left(\frac{t-\tau}{a}\right) dt \dots\dots\dots (3.1)$$

其中, $f(t)$ 表示原始的信号, a (scale) 为控制函数伸缩的尺度变量, τ (translation) 为控制平移位置的平移变量。

小波变换的一个优点就是具有多尺度的特点, 可以按照不同的尺度来观察信号, 并且在观察过程中可以自动的调节尺度, 如对于波形较为平缓的地方, 可以用大尺度进行分辨, 对于波形变化较为剧烈的地方, 可以使用小尺度进行分辨, 尽可能的不忽略细节的获取到波形信息。因此利用小波变换提取运动轨迹的小波域特征, 可以得到运动过程中轨迹的微小细节变化以及整体变化趋势。

波形具有高频的部分和低频的部分, 由此对应低通以及高通的滤波器, 对波形进行滤波, 这样对于不同尺度空间可以得到不同的波形变换:

$$A_{j+1}(n) = H(n) * A_j(n) \dots\dots\dots (3.2)$$

进一步

$$A_{j+1}(n) = \sum_k H(k) A_j(2n+k) \dots\dots\dots (3.3)$$

$$D_{j+1}(n) = G(n) * A_j(n) \dots\dots\dots (3.4)$$

进一步

$$D_{j+1}(n) = \sum_k G(k)A_j(2n-k) \cdots \cdots (3.5)$$

其中, $H(n)$ 和 $G(n)$ 分别为小波函数对应的低通和高通滤波器的抽头系数序列。 $A_{j+1}(n)$ 和 $D_{j+1}(n)$ 分别表示原始波形的近似信号和细节信号。本文在提取过程中采用最传统的 harr 小波, 如图 3.2 所示为提取的某一婴儿样本的运动轨迹波形的波形近似图, 该图反映了婴儿运动轨迹的波形信号在小波域下的呈现情况。

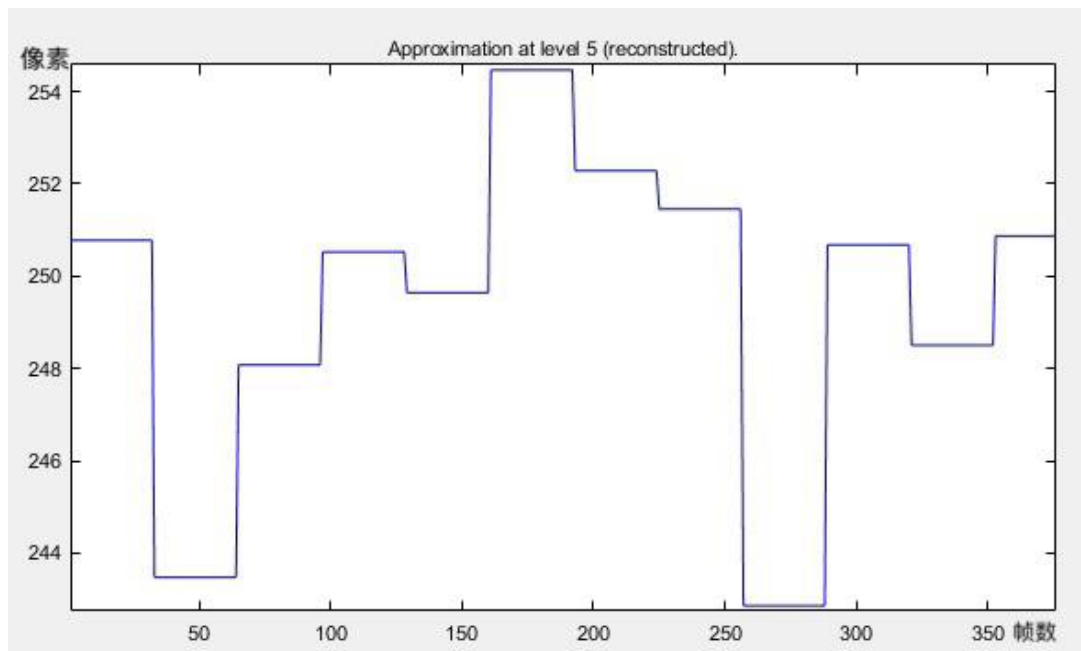


图 3.2 运动轨迹小波波形图

3.3 运动轨迹功率信息分析

对于婴儿左上肢, 右上肢, 左下肢, 右下肢以及全身的运动轨迹的分析, 由于时频特性的对应关系, 在考虑提取运动轨迹的小波特征情况下, 相应的研究运动轨迹的频谱特征是否也包含特异性, 对婴儿四肢及全身的运动轨迹进行功率谱分析。对于周期性连续信号 $f(t)$ 的频谱 $f\omega$ 幅度的平方就被称之为该信号的功率谱, 根据功率谱信息, 我们可以看出单位时间频率内, 信号所包含的能量的多少, 因此通过对原始信号进行小波变换, 然后计算幅度频谱的平方, 即可得出信号的功率谱信息。如图 3.3 所示为某一波形得到的功率谱图。

$$p = |f(n)|^2 \cdots \cdots (3.6)$$




图 3.3 运动轨迹功率谱图

3.4 婴儿运动速度加速度分析

婴儿异常行为的一个特点是全身进行运动时运动具有停滞感,且看不到加速度可变的并且遍布各个不同方向的小幅度运动。由此考虑在婴儿运动时,其四肢运动的速度特性,加速度特性作为两项判断婴儿行为是否异常的指标。

由传统物理学可知速度 v 及加速度 a 的计算公式分别为:

$$v = s/t \dots\dots\dots (3.7)$$

$$a = v/t \dots\dots\dots (3.8)$$

其中 s 为路程, t 为时间,根据第 2 章中得到的婴儿左上肢,右上肢,左下肢,右下肢以及全身的运动轨迹,由运动轨迹波形图可知婴儿的运动是非匀速的曲线运动,因此在求其速度和加速度时,可详细到求取每两帧之间的速度和加速度,从而得到一个关于速度的变化特征矩阵和一个关于加速度的变化特征矩阵。

3.4.1 婴儿运动速度特征

对于婴儿的速度,根据第 2 章可以得到婴儿的四肢和全身的运动轨迹以及每帧婴儿目标的横纵坐标位置,一般规定视频的帧率为 25 帧每秒,可得到每两帧的时间间隔为 0.04 秒,间隔相当短,因此可以将每两帧之间的不规则的运动轨迹曲线量化为近似的直线,由此对于每两帧间的路程 S ,便可以用简单的勾股定理得出,公式如下:

$$S_{t+1} = \sqrt{(y_{t+1} - y_t)^2 + (x_{t+1} - x_t)^2} \dots\dots\dots (3.9)$$

其中, y 为帧时刻的婴儿运动轨迹的纵坐标。 x 为帧时刻的婴儿运动轨迹的横坐标。下标为帧序号, 即下标 t 表示第 t 帧信息, 下标 $t+1$ 表示第 $t+1$ 帧信息。由于本文统计的不是具体的速度大小, 而是速度的一个变化趋势, 因此为了方便计算, 将时间间隔默认为 1, 由此得出婴儿左上肢, 右上肢, 左下肢, 右下肢以及全身的运动轨迹的速度特征向量, 如图 3.4 所示为某一婴儿样本提取到的运动速度变化图, 此运动速度变化图是经过归一化后的结果。





图 3.4 婴儿运动速度变化图

3.4.2 婴儿运动加速度特征

对于婴儿运动的加速度特征向量, 根据加速度的物理定义, 其是有方向有大小的向量, 联系速度与加速度的关系, 在速度特征向量的基础上, 还需要一个方向向量 α , 即:

$$\alpha = \arctan\left(\frac{y_{t+1} - y_t}{x_{t+1} - x_t}\right) \dots\dots\dots (3.10)$$

其中, x, y 的定义同上, 下标为帧序号, 由此可得出婴儿左上肢, 右上肢, 左下肢, 右下肢以及全身的运动轨迹的加速度特征向量, 如图 3.5 所示为某一婴儿样本提取到的运动加速度变化图, 此运动加速度变化是经过归一化后的结果。



3.5 婴儿运动加速度变化

3.5 婴儿目标的质心分析

对于婴儿目标的质心的研究,主要分为婴儿目标质心的个数和婴儿目标物理中心的质心变化两部分。

3.5.1 婴儿目标质心的个数

考虑婴儿目标的质心的个数,是因为婴儿的大致位置基本不动,只是四肢和全身的一个扭动过程,换句话说,可以看作是以婴儿的几何中心为原点,四肢围绕几何中心的一个绕轴运动过程。因此考虑从视频中提取目标婴儿部分,也就是前景部分,通过整个视频的所有帧叠加过程,得到婴儿扭动时所占面积,即婴儿扭动时所触及到的全部区域,然后统计其中的连通区域,计算质心位置,观察质心的数量情况。

在统计婴儿的质心的个数时,首先要提取目标婴儿区域,也就是区分前景部分和背景部分,这个过程利用简单的背景差分法就可以实现。该方法顾名思义就是利用做差的方法得到目标区域的灰度图,在做差的过程中由目标减去了背景便可以提取出运动的目标区域。然后设定一个阈值,对得到的关于目标灰度图进行判断,即可提取出运动区域。而且背景图像根据当前获取图像帧会进行更新,这样可以避免环境变化的影响。大致流程为:

(1) 取前几帧的图像的平均值,将这样形成的图像作为背景 Imb ;

(2) 将当前帧图像 Im 与背景帧图像相减,即利用图像的像素灰度进行相减,并且对相减的运算结果取绝对值 B :

$$B = |Im(x, y) - Imb(x, y)| \cdots \cdots (3.11)$$

(3) 对当前帧的像素 (x,y) 进行判断, 设置阈值 T , 如果 $B>T$, 该像素点为前景点; 反之, 如果 $B\leq T$. 则该像素点为背景点;

(4) 用当前帧图像对背景图像进行更新, 重复以上过程直到所有的视频帧都检测完毕。

如图 3.6 为所有样本中的两个婴儿例子, 图 (a) 和图 (c) 是整段视频运动前景叠加后得出的婴儿运动区域的两个例子, 对于这个运动区域, 由于连通的区域在某些部位并没有得到清晰的划分, 因此, 还要对结果进行边缘处理, 选择 Sober 算子对目标区域进行边缘处理, Sober 算子通过检测边缘点, 突出边缘位置从而得到多个连通域。在具体操作时先用腐蚀和膨胀消除边缘的毛刺以及噪声, 然后用 Sober 算子提取婴儿目标的边缘, 形成多个连通区域, 得到如图 (b) 和图 (d) 的效果。本文利用背景差分法对目标婴儿的视频进行目标提取, 叠加出婴儿在整段视频中运动所经过并包含的位置, 然后用 Sober 算子处理目标婴儿运动区域的边缘轮廓, 构成多个清晰的连通区域。根据用 Sober 算子处理后的图像, 计算每个连通区域的中心, 以该中心做为这一部分质心的位置, 然后统计婴儿的质心的个数作为婴儿目标质心的个数特征。




图 3.6 婴儿目标提取及连通区域判定

3.5.2 婴儿目标质心位置变化

而对于婴儿目标质心的变化特征,本文中分别对婴儿的四肢以及全身五部分分别进行了目标跟踪,因此在考虑质心变化时也分别选择左上肢,右上肢,左下肢,右下肢以及全身的质心情况。由于婴儿的质量分布是均匀的,所以分别选择每部分的几何中心作为质心的位置,然后观察其变动情况。统计婴儿各个部位的质心波动变化情况,也就是在记录婴儿运动过程中肢体运动的幅度变化情况。在试验中所有的婴儿样本运动时左右扭动幅度区别不大,主要考虑质心的上下位置波动变化情况,因此只需考虑纵坐标的变化情况即可。在实际操作时,本文通过分别跟踪目标婴儿的四肢及全身这五部分,定位每一帧目标所在的位置,在跟踪的过程中根据目标所在位置,采集每一帧婴儿的四肢以及全身的质心的位置,并记录相邻帧之间质心变化的差,将一段完整的婴儿运动视频中的所有相邻帧质心变化差矩阵作为婴儿目标质心位置变化的特征。如图 3.7 所示为对某一婴儿样本提取到的质心变化特征,可以看出婴儿的质心位置一直处于不规则的波动状态。




图 3.7 婴儿运动质心变化

3.6 本章小结

本章结合第 2 章对婴儿目标进行四肢以及全身跟踪结果,分别就基于运动轨迹的分析和基于人体特征的分析提取关于婴儿的多组特征。在联系非平稳信号的特点提取了目标婴儿运动轨迹的小波域特征;在结合时域频域的对特点提取了婴儿运动轨迹的功率谱域特征;通过分析婴儿运动提取了婴儿运动时的速度特征以及加速度特征;根据婴儿进行肢体运动时人体本身所包含的特质,提取了婴儿质心的个数特征以及婴儿质心的变化特征。对

这几组特征分别加以介绍和提取，对每组特征分别制作正常样本和异常样本的样本集，为下一步的多特征融合做了铺垫。

第4章 婴儿异常行为分析

4.1 基于多特征融合的婴儿异常行为判断框架

本文在对婴儿的神经发育异常医学原因及特征表象的研究基础下,对婴儿的多种特征分别进行了分析和比较,结合第2章基于注意力机制的对婴儿目标的跟踪,第3章对于婴儿运动特征的提取以及本章前面所述对婴儿特征的分析,提出了一种基于多特征融合的婴儿异常行为检测框架,基本框架流程如图4.1所示。

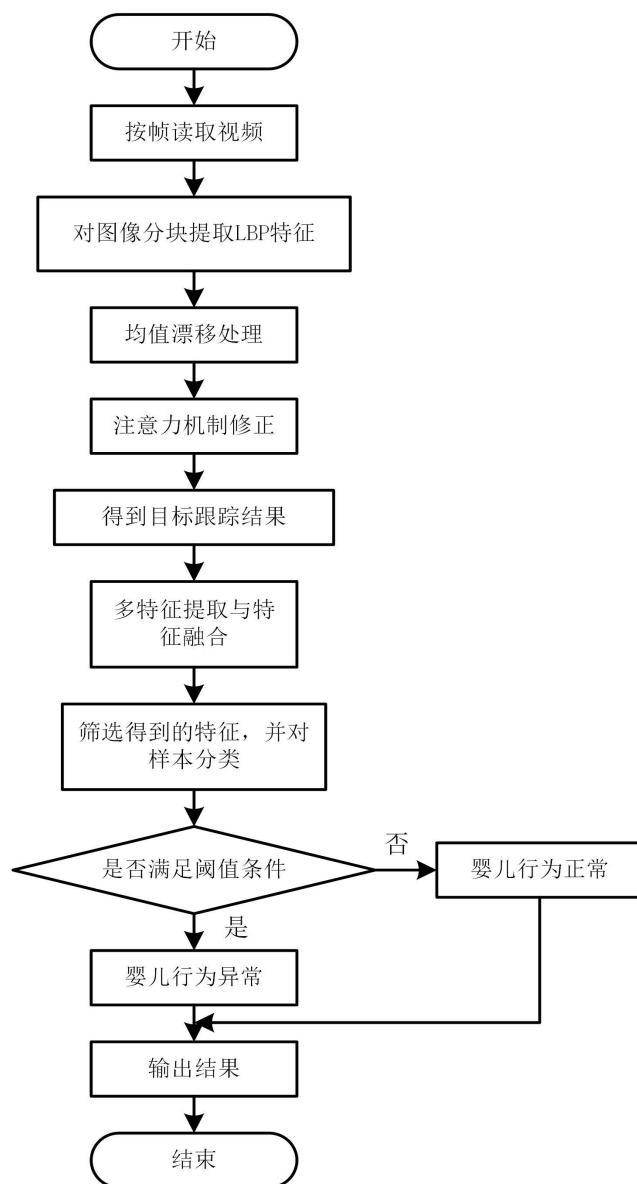


图 4.1 基于多特征融合的婴儿异常行为检测流程图

本文提出的基于多特征融合的婴儿异常行为检测模型,其基本思想是通过对婴儿的四肢以及全身这五部分进行目标跟踪,结合基于运动模式的特点以及基于人体本身特质的特点,提取多组与婴儿运动有关的特征,对多组特征进行加权融合,最终得出婴儿运动行为是否存在异常的结论。在前文中已经进行了婴儿目标的跟踪,婴儿多组特征的提取并且建立了相对应特征的样本库,接下来便是对于多组特征的一个详细对比分析,从而筛选出最优的特征组合,作为最终的判断依据,判断婴儿行为是否异常的研究。在特征分类时本文用到支持向量机,而在特征组合时本文用到了自适应的多特征融合方法,并且分别对几组特征进行了分类和组合特征进行了分类,对结果进行比较,最终提出一种最有效的特征组合方式用来判断婴儿的行为是否异常。利用多特征融合的方式完成婴儿异常行为的检测。

4.2 婴儿特征数据分析

第3章通过婴儿运动特征的提取分别得到了婴儿的多组特征,包括婴儿运动轨迹的小波域特征、婴儿运动轨迹的功率谱特征、婴儿运动的速度特征、婴儿运动的加速度特征、婴儿质心个数特征以及婴儿质心变化特征。本章首先对这几组特征分别进行分析对照,然后从各组特征中选择最佳的特征组合,最后利用分类器对多组特征进行分类判断分析。

由于婴儿样本的个数有限,而样本的某些特征的维度相较于样本个数比较多,因此首先要对样本的这些特征进行降维处理。

4.2.1 特征降维

由于现实中处理的数据通常都是多维的,在大数据且多维的情况下,会造成算法的复杂度很高甚至呈指数型增长,从而造成维度灾难。而在数据样本较小,但数据的维度很大的情况下,对数据的分析的过程中很容易造成过拟合,从而无法得到理想的结果。在数据表现方面,通常无法观察三个维度以上的特征表现情况,因此对于特征降维,不仅可以在低维度上更好的观察数据,而且还可以使数据有更强的展现能力。特征降维使数据集更容易被使用,降低了算法开销和复杂度,减轻了过拟合现象,更易于获取有价值的信息,为更方便高效的处理高维度特征提供了方式。因此对于第3章所提取的几组婴儿特征,对于特征维度高的特征,首先要采取的就是特征降维处理。

目前比较有代表性且较为常用的如线性判别分析(Linear Discriminant Analysis, LDA)以及主成分分析法(Principal Components Analysis, PCA)。

(1) 线性判别分析法 LDA

线性判别分析法是一种有监督的降维算法。它的中心思想是使样本的类间距离最大和使样本的类内距离最小。即找一个投影方向,使投影之后原来的处于不同种类的样本尽可能被划分开。用这样投影的方式找到一个新的空间,将原始样本按他们的类别在新的空间尽可能分开,既保持了原本的类别不同的信息,同时也降低了维数,达到了降维的效果。这是一种有效的特征提取方法,当使用 LDA 方法降维时,散布矩阵会发生变化,即类内

的最大，类间的最小。

对于线性判别分析法，首先定义给定数据集 $\{(x_i, y_i)\}$ ， i 表示第几类，一共有 m 类。其中第 i 类的均值向量为 μ_i ，第 i 类的协方差矩阵为 Σ_i ，两类样本的中心在直线上的投影分别为 $w^T \mu_0$ 和 $w^T \mu_1$ ，两类样本的协方差分别为 $w^T \Sigma_0 w$ 和 $w^T \Sigma_1 w$ 。

定义类内散度矩阵如下：

$$s_w = \Sigma_0 + \Sigma_1 \cdots \cdots \cdots (4.1)$$

类间散度矩阵如下：

$$s_b = (\mu_0 - \mu_1) \cdot (\mu_0 - \mu_1)^T \cdots \cdots \cdots (4.2)$$

最终目标是使样本数据的类间间距最大，使样本数据的类内间距最小。即最大化下式：

$$J = \frac{\|w^T \mu_0 - w^T \mu_1\|_2^2}{w^T \Sigma_0 w + w^T \Sigma_1 w} \cdots \cdots \cdots (4.3)$$

进一步：

$$J = \frac{w^T (\mu_0 - \mu_1) (\mu_0 - \mu_1)^T w}{w^T (\Sigma_0 + \Sigma_1) w} \cdots \cdots \cdots (4.4)$$

代入类内散度和类间散度得最终最大化广义瑞利熵：

$$J = \frac{w^T s_b w}{w^T s_w w} \cdots \cdots \cdots (4.5)$$

通过计算类内及类间散度最大化广义瑞利熵，即可得到最佳的降维投影方向。

(2) 主成分分析法 PCA

主成分分析法是一种无监督的降维算法。它的中心思想是要最大化投影方差，让特征数据在主轴上的投影的方差最大。具体推导如下：

给定一组数据点 $\{v_1, v_2, \dots, v_n\}$ ，其中所有向量均为列向量，中心化后表示为 $\{x_1, x_2, \dots, x_n\}$ ，其中：

$$\{x_1, x_2, \dots, x_n\} = \{v_1 - \mu, v_2 - \mu, \dots, v_n - \mu\} \cdots \cdots \cdots (4.6)$$

$$\mu = \frac{1}{n} \sum_{i=1}^n v_i \cdots \cdots \cdots (4.7)$$

向量内积在几何上表示为第一个向量投影到第二个向量上的长度，所以 x_i 在 w （单位方向向量）上的投影坐标为：

$$(x_i, w) = x_i^T \cdot w \cdots \cdots \cdots (4.8)$$

所以目标是找一个投影方向 w ，使 x_1, x_2, \dots, x_i 在 w 上进行投影的时候，它的方差尽可能大。投影方差为：

$$D(x) = \frac{1}{n} \sum_{i=1}^n (x_i^T \cdot w)^2 \cdots \cdots \cdots (4.9)$$

进一步：

$$D(x) = w^T \left(\frac{1}{n} \sum_{i=1}^n x_i \cdot x_i^T \right) w \cdots \cdots (4.10)$$

由此得出最佳投影方差就是协方差矩阵的特征值。对应的我们所要寻找的最佳投影方向就是协方差矩阵的最大特征值所对应的特征向量。

主成分分析法(PCA)的求解步骤流程图如图 4.2 所示:

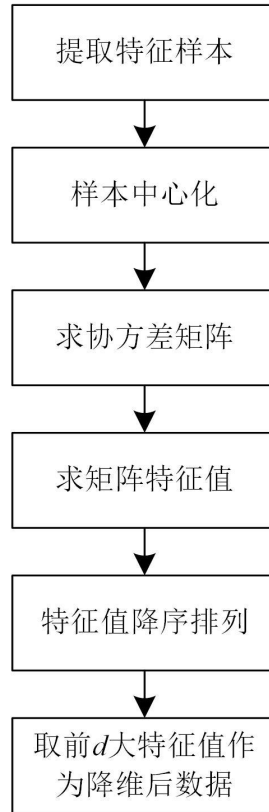


图 4.2 PCA 降维流程图

对于取前 d 大特征值计算新的降维数据这一过程,具体来说是定义前 d 大特征值对应的特征向量为 w_1, w_2, \dots, w_d , 根据式 4.11 计算降维后的数据:

$$x'_i = \begin{bmatrix} w_1^T \cdot x_i \\ w_2^T \cdot x_i \\ \vdots \\ w_d^T \cdot x_i \end{bmatrix} \cdots \cdots (4.11)$$

新的 x'_i 的第 d 维就是 x_i 在第 d 个主成分 w_d 方向上的投影。

由于在本文中对特征降维时不希望用到特征究竟属于哪一类这个信息,希望只针对最原始的得到的数据进行降维处理,对处理后的数据再进行分类,因此在特征降维时选择主成分分析法(PCA)来降维。本文分别对婴儿运动轨迹的小波域特征,婴儿运动的速度特征,婴儿运动的加速度特征以及婴儿质心变化特征进行了 PCA 降维处理,对各组特征进行处理之后,便可以对婴儿的几组特征分别进行特征分析和比较。

4.2.2 特征分析

(1) 婴儿运动轨迹小波域特征分析

对于婴儿运动轨迹的小波域特征,首先用 PCA 分析法对该特征的样本进行降维处理。然后将婴儿正常样本和婴儿异常样本的小波域特征描绘在一幅图像上进行比较,婴儿运动轨迹的小波域特征如图 4.3 所示。

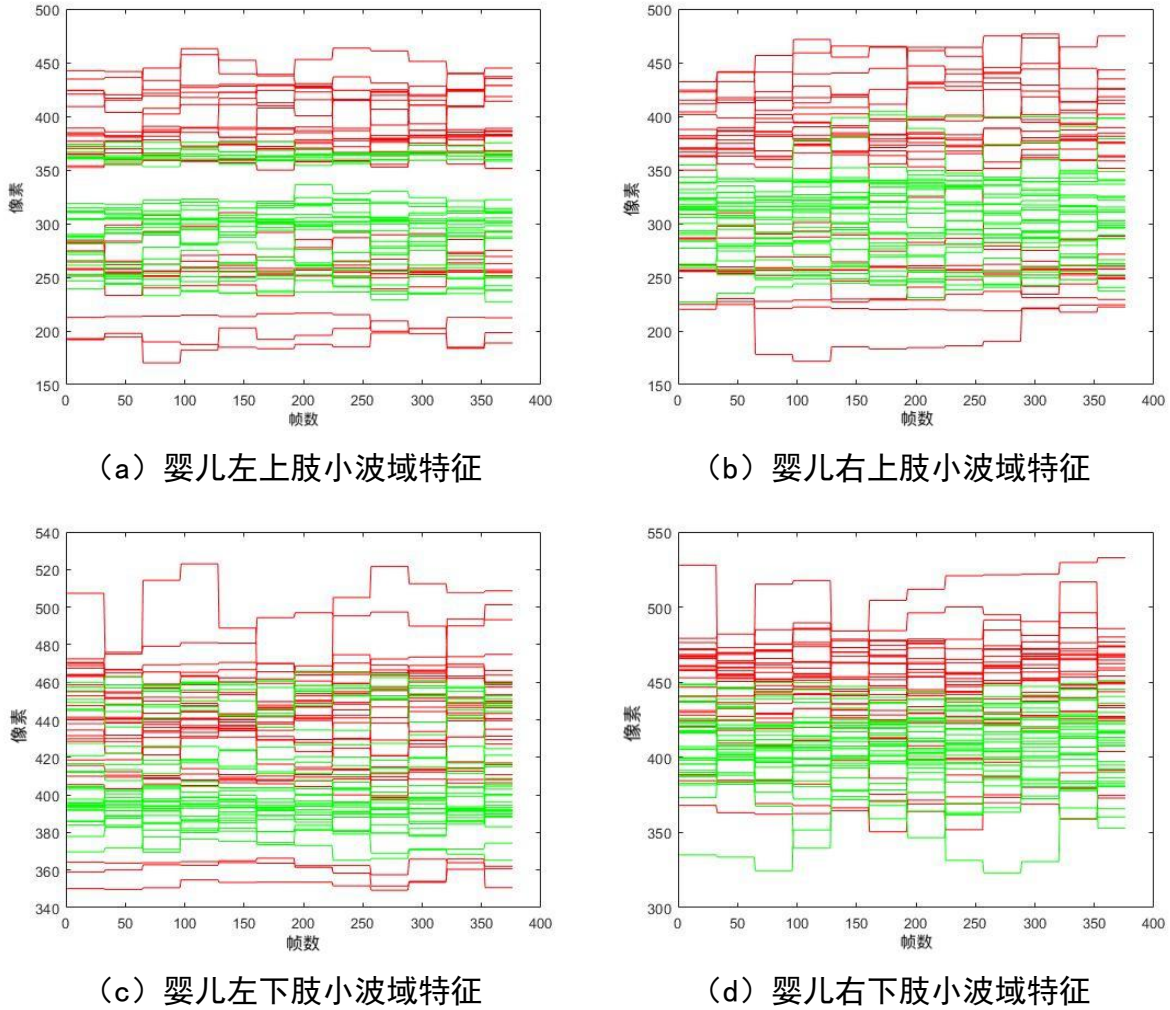


图 4.3 婴儿四肢运动轨迹小波域特征

如图 4.3 中的 (a)、(b)、(c)、(d) 所示分别对应婴儿四肢的小波波形近似图,其中绿色波形线为 30 个临床 GMs 评估异常婴儿的样本,红色波形线为 30 个临床 GMs 评估正常婴儿的样本。由图中可以看出,行为异常的婴儿的小波波形近似图相较于行为正常的婴儿小波波形近似图更为集中在一定的范围之内,而正常婴儿的运动波形图则更加分散无规律。这也反映了异常婴儿在运动过程中四肢的运动模式要更加僵硬,只集中在一定范围,而正常婴儿在运动过程中四肢的摆动显得更为流畅和不具有预测性,更加的分散无特定性。

(2) 婴儿运动轨迹功率谱特征分析

对婴儿运动轨迹的功率谱特征并不需要进行降维处理,直接对其进行分析。婴儿运动

轨迹功率谱域特征如图 4.4 所示。图 4.4 中的 (a)、(b)、(c)、(d) 分别对应婴儿的四肢功率谱曲形图, 其中红色曲线表示 30 个临床 GMs 评估正常婴儿的功率谱, 绿色曲线表示 30 个临床 GMs 评估异常婴儿的功率谱, 从图中可以看出正常婴儿运动轨迹在相同频率的情况下功率谱的幅度比异常婴儿运动轨迹的更高。这也说明在同样的低频谱水平下, 正常婴儿的平均功率会更高一些, 能量更加的集中, 而异常婴儿的功率谱总体来说会偏低一点。

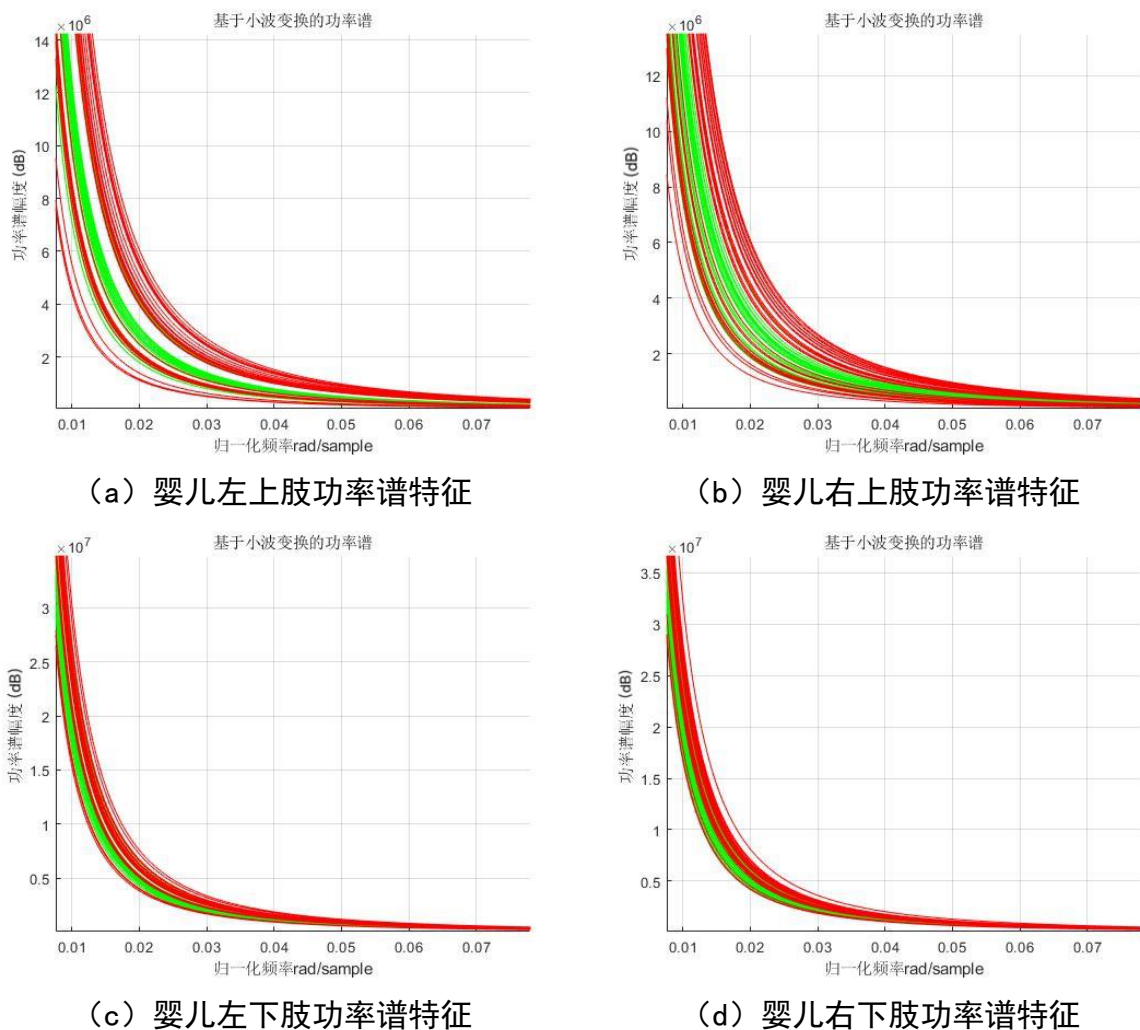


图 4.4 婴儿四肢运动轨迹功率谱特征

(3) 婴儿运动速度分析

对于婴儿运动速度, 由于不同样本的速度差距很大, 为了方便观察和分析比较, 首先对得到的速度样本进行归一化, 选用的方法为最大最小归一化法。所谓最大最小归一化法, 就是把原有的数据用线性的方法转化到[0,1]区间内。而最大最小归一化法, 顾名思义, 要用到数据样本的最大值和最小值。其计算公式如下:

$$x = (x - x_{\min}) / (x_{\max} - x_{\min}) \cdots \cdots (4.12)$$

其中, x 为数据样本集, 定义该样本集最小值为 x_{\min} , 最大值为 x_{\max} 。最大最小归一化法的一个问题是当有新数据加入时, 需要重新进行计算得到最大最小值, 但本文由于运动轨迹给定后, 计算得到的速度样本数据集不会有新数据的加入, 因此不用担心新数据

加入是否要重新计算的问题。如图 4.5 所示分别为某一异常婴儿样本和某一正常婴儿样本的速度分析图，从图中并不能清晰的对比出正常婴儿和异常婴儿的运动速度区别。为了进一步的分析速度特征，再对正常婴儿样本和异常婴儿样本的速度分布直方图进行比较。






图 4.5 婴儿运动速度分析

进一步对婴儿运动速度分析，考虑其速度大小的分布情况，分别对 30 个正常婴儿样本以及 30 个异常婴儿样本求速度分布直方图，如图 4.6 所示。




(a) 异常正常婴儿左上肢速度分布直方图

(b) 异常正常婴儿右上肢速度分布直方图



(c) 异常正常婴儿左下肢速度分布直方图 (d) 异常正常婴儿右下肢速度分布直方图



(e) 异常正常婴儿全身速度分布直方图

图 4.6 婴儿运动速度分布直方图

如图 4.5 和图 4.6 分析, 婴儿运动速度不论是从单个样本分析比较, 还是从整体速度分布直方图比较, 正常婴儿样本和异常婴儿样本的差距都不是很明显, 具体结果还要送入分类器进行分类判断。

(4) 婴儿运动加速度分析

对于婴儿运动的加速度, 着重关心其方向的变化。在对婴儿运动的加速度分析中, 大小的变化体现在了速度的数据中, 因此只提取它的方向特征信息组成关于婴儿运动加速度特征的数据集。如图 4.7 所示为某一异常婴儿样本和某一正常婴儿样本加速度方向的数据分析。






图 4.7 婴儿运动加速度分析

进一步对婴儿运动的加速度分析，考虑其加速度方向的分布情况，分别对 30 个正常婴儿样本以及 30 个异常婴儿样本求加速度分布直方图，如图 4.8 所示。



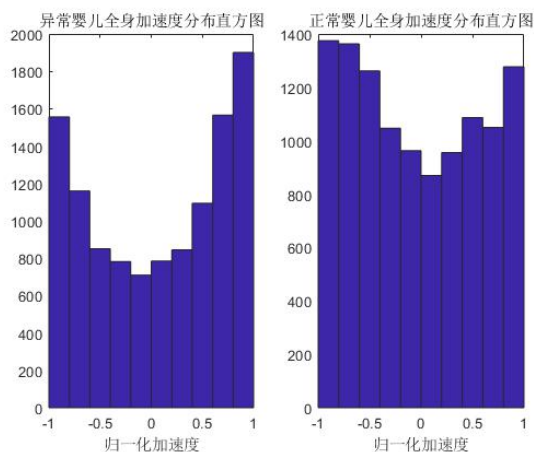
(a) 异常正常婴儿左上肢加速度直方图

(b) 异常正常婴儿右上肢加速度直方图



(c) 异常正常婴儿左下肢加速度直方图

(d) 异常正常婴儿右下肢加速度直方图



(e) 异常正常婴儿全身加速度直方图

图 4.8 婴儿运动加速度分布直方图

如图 4.7 和图 4.8 分析，婴儿运动加速度不论是从单个样本分析比较，还是从整体加速度分布比较，正常婴儿样本和异常婴儿样本关于加速度的差距都不是很明显，具体结果还要送入分类器进行分类判断。

(5) 婴儿质心的分析

本文从婴儿质心个数以及质心变化这两个维度进行了特征采样，如图 4.9 所示为 60 个正常婴儿样本和 60 个异常婴儿样本质心个数分布比较。




图 4.9 婴儿质心个数比较

从图 4.9 婴儿质心个数比较来看,异常婴儿样本的质心个数在一定程度上都要比正常婴儿样本质心个数要多,但也存在容易混淆的部分,因此,是否能作为判断依据还是要送入分类器进行分类判断分析。

对于婴儿质心的变化,主要考虑婴儿质心的上下位置波动变化情况,只需采集纵坐标的变化情况即可,采集每一帧质心的位置,记录相邻帧质心变化差作为婴儿质心特征。对于婴儿质心的变化同样分为单个样本的质心变化比较以及多个样本质心分布直方图进行比较。如图 4.10 所示,为某单个异常婴儿样本和某单个正常婴儿样本质心变化分析。从图 4.10 可以看出正常样本的质心变化和异常样本的质心变化是有一定区别的,异常婴儿运动质心波动更大一些,而正常婴儿运动质心波动较小一些。具体是否可以做为最终的判断依据还要用分类器进行分类比较分析。






图 4.10 婴儿运动质心分析


进一步对婴儿运动质心分析,考虑其质心的分布情况,分别对 30 个正常婴儿样本以及 30 个异常婴儿样本求质心分布直方图,如图 4.11 所示。从图中可以看出,虽然正常样本和异常样本的质心分布都比较集中在中间位置,但异常样本要更加集中,而正常婴儿样本质心分布相比异常婴儿样本要更分散一些。



(a) 异常正常婴儿左上肢质心分布直方图 (b) 异常正常婴儿右上肢质心分布直方图



(c) 异常正常婴儿左下肢质心分布直方图 (d) 异常正常婴儿右下肢质心分布直方图



(e) 异常正常婴儿全身质心分布直方图

图 4.11 婴儿运动质心分布直方图

4.3 基于多特征融合的婴儿异常行为分析

4.3.1 支持向量机算法

本文使用支持向量机(SVM)作为上述提取到的特征的分类器。该方法主要根据核函数的不同而进行不同方式的分类,使用十分灵活。支持向量机算法旨在解决分类的问题和回归的问题,它的中心思想是在特征空间上找到一个最优的超平面,这个超平面可以最大限度的分开不同类的样本,距离这两种不同样本的间隔都最大。

通俗的来讲,支持向量机想达到的效果就是选择一个最佳的分类超平面。在经过投影之后,属于不同类的样本,距离最远,被很好的分割开来。设一个训练样本集 $\{(x_i, y_i)\}$,支持向量机的目标是选择一个超平面,使得正负样本和这个超平面的距离都是处于最大化程度。如图 4.12 所示,其中 B 分割超平面和 C 分割超平面虽然距离其中某类样本间隔很大,可对另一类样本的间隔就很小,这样整体对于正负样本间隔不是最大的,分类出的结果往往会倾向于其中某一个类别,从而使样本集中的数据的分类结果都尽可能的归于了其中一类,造成误分类的样本个数偏多。相反的, A 分割超平面可以使得不同类的样本的间隔最大化,并不偏颇于其中的某一类样本。这样达到的分类效果最佳,因此在选取超平面时, A 分割超平面便是最佳的选择。




图 4.12 支持向量机最佳分割超平面的选择

对于支持向量机,通常根据数据是否线性可分,分为线性可分支持向量机(硬间隔支持向量机),线性支持向量机(软间隔支持向量机)以及非线性支持向量机。对于数据线性可分时,选取硬间隔支持向量机;对于数据近似线性可分时,选取软间隔支持向量机;而对于线性不可分的数据选取非线性支持向量机。

首先设学习得到的分离超平面为:

$$w^* \cdot x + b^* = 0 \cdots \cdots \cdots (4.13)$$

相应的分类决策函数为:

$$f(x) = \text{sign}(w^* \cdot x + b) \cdots \cdots \cdots (4.14)$$

对于给定的训练集 T 和超平面 (w, b) ，定义超平面 (w, b) 关于 T 的函数间隔为 (w, b) 关于 T 中所有数据样本的函数间隔最小值，即函数间隔为：

$$\hat{r} = \min_{i=1 \dots N} y_i (w_i \cdot x + b) \cdots \cdots \cdots (4.15)$$

定义超平面 (w, b) 关于 T 的几何间隔为 (w, b) 关于 T 中所有样本点几何间隔的最小值，即几何间隔为：

$$r = \min_{i=1 \dots N} y_i \left(\frac{w}{\|w\|} \cdot x_i + \frac{b}{\|w\|} \right) \cdots \cdots \cdots (4.16)$$

最大化几何间隔，所求条件如下式：

$$\max r \quad \text{s.t.} \quad y_i \left(\frac{w}{\|w\|} \cdot x + \frac{b}{\|w\|} \right) \geq r \cdots \cdots \cdots (4.17)$$

也可写作：

$$\max \frac{\hat{r}}{\|w\|} \quad \text{s.t.} \quad y_i (w \cdot x_i + b) \geq \hat{r} \cdots \cdots \cdots (4.18)$$

由于函数间隔改变不影响超平面位置，因此为方便计算取函数间隔为 1。上式可化为：

$$\min \frac{1}{2} \|w\|^2 \quad \text{s.t.} \quad y_i (w \cdot x_i + b) - 1 \geq 0 \cdots \cdots \cdots (4.19)$$

接下来要做的便是针对该约束条件对训练集 T 求最优的 w 和 b 。支持向量是指在线性可分的情况下，训练集的样本点中与分离超平面距离最近的样本点的实例。即支持向量是使约束条件等号成立的样本点。

根据条件，对于正样本，支持向量在超平面：

$$H_1 : w \cdot x + b = 1 \cdots \cdots \cdots (4.20)$$

对于负样本，支持向量在超平面：

$$H_2 : w \cdot x + b = -1 \cdots \cdots \cdots (4.21)$$

在决定分离超平面时只有支持向量起作用。

由于数据并不都是线性可分的，往往为近似可分和非线性，因此为了避免过拟合，常会加入惩罚参数 C 和松弛变量 ξ ，使支持向量机在保持分类准确性的同时减少过拟合的可能，一般情况下惩罚参数越大，说明分类的条件越苛刻，稍有错误就会对错误的样本加大惩罚。这样也存在造成过拟合的风险。改进的约束最优化问题变为下式：

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^N \xi_i \quad \text{s.t.} \quad y_i (w \cdot x_i + b) \geq 1 - \xi \cdots \cdots \cdots (4.22)$$

根据上述约束条件，在求解最优 w 和 b 时，用到对偶算法，构造拉格朗日函数：

$$L(w, b, \alpha) = \frac{1}{2} \|w\|^2 - \sum_{i=1}^N \alpha_i y_i (w \cdot x_i + b) + \sum_{i=1}^N \alpha_i \cdots \cdots \cdots (4.23)$$

其中 $\alpha = (\alpha_1, \dots, \alpha_N)^T$ 为拉格朗日乘子向量。所求变为 $\max_{\alpha} \min_{w, b} L(w, b, \alpha)$ 。在实际操作中，分别求导构造出最优化问题为：

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j (x_i \cdot x_j) - \sum_{i=1}^N \alpha_i \quad s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0, 0 \leq \alpha_i \leq C \quad (4.24)$$

可求得最优解 $\alpha^* = (\alpha_1^*, \alpha_2^*, \dots, \alpha_N^*)^*$ ，进一步得最优 w 和 b ：

$$w^* = \sum_{i=1}^N \alpha_i^* y_i x_i \quad (4.25)$$

$$b^* = y_j - \sum_{i=1}^N \alpha_i^* y_i (x_i \cdot x_j) \quad (4.26)$$

进一步便可得到最佳的分离超平面和决策函数。

本文对于婴儿的特征样本进行分类，这是一个非线性分类问题，在处理非线性问题时，一般考虑要将其变换成线性的问题进行处理。具体操作是用一个非线性变换，将输入空间映射到一个指定的特征空间，在这个特征空间里，原本要求解的超曲面模型，变成了超平面模型。在映射之后的空间，按前面所述的方法求解最佳的参数去对样本数据进行分类。而在映射的过程中存在核函数的计算。它是一个从输入空间到特定的特征空间的映射函数的内积。常用的核函数有多项式核函数，高斯径向基核函数，线性核函数等。鉴于高斯径向基核函数对大样本和小样本都有较好的效果，并且参数比多项式核函数要少很多，因此成为首选。高斯径向基核函数的表达式为：

$$k(x, z) = \exp\left(-\frac{\|x - z\|^2}{2\sigma^2}\right) \quad (4.27)$$

在处理关于婴儿的非线性特征样本时，最重要的是选合适的核函数，以及恰到好处的惩罚参数。构造并求解变为如下式所示：

$$\min_{\alpha} \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j k(x_i, x_j) - \sum_{i=1}^N \alpha_i \quad s.t. \quad \sum_{i=1}^N \alpha_i y_i = 0, 0 \leq \alpha \leq C \quad (4.28)$$

最终构造决策函数为：

$$f(x) = \text{sign}\left(\sum_{i=1}^N \alpha_i^* y_i k(x \cdot x_i) + b^*\right) \quad (4.29)$$

后续本文中利用 SVM 对前文提取的多组特征进行分别的分类判断以及组合的分类判断。

4.3.2 多特征融合及结果分析

在前一部分中分别对婴儿的左上肢，右上肢，左下肢，右下肢以及全身建立了 SVM 训练模型，要最后综合得出婴儿行为是否正常的判断时，就必须分别对这 5 个模型进行数据加权融合综合判断，通过数据加权融合算法对 5 个模型赋予不同的权值，得出综合的结果。

其中，在处理这五个模型的融合问题时，本文选用自适应的方法来对目标婴儿特征模型进行加权融合。根据婴儿的不同的特征训练的模型所得到的测量值，用自适应方法，找

到对应于各个婴儿特征模型的最优的加权因子。并分别赋予这五部分，使得融合后的判断值达到最优，具体的加权计算操作方法如下所述。

将各个模型训练的准确率看作预测值，记作 x_1, x_2, \dots, x_5 ，对应的加权因子记作 w_1, w_2, \dots, w_5 。对于融合后得到的预测值 X ，满足：

$$X = \sum_{p=1}^n w_p x_p \cdots \cdots (4.30)$$

$$\sum_{p=1}^n w_p = 1, n=5 \cdots \cdots (4.31)$$

均方误差 σ^2 为：

$$\sigma^2 = \sum_{p=1}^n w_p^2 \sigma_p^2, n=5 \cdots \cdots (4.32)$$

要求最佳的加权因子，就是使均方误差 σ^2 最小。此时加权因子为：

$$w_p^* = 1 / \left(\sigma_p^2 \sum_{i=1}^n \frac{1}{\sigma_i^2} \right), n=5 \cdots \cdots (4.33)$$

对于 SVM 的训练，最重要的是选择合理的 SVM 中的参数 c 和 g ，其中 c 是惩罚因子， g 是核函数中的设置项，这些参数可以在训练的操作程序过程中进行自动寻优。

训练模型得出后，对这些模型进行加权融合，通过这一过程对不同准确率的模型赋予不同权重，从而使最终判断结果准确率最高。对融合后的判断结果进行测试，取 30 个随机样本，对婴儿运动轨迹的小波域特征训练出的模型，测试对应左上肢、右上肢、左下肢、右下肢和全身整体的结果，分别命名为 AP1、AP2、AP3、AP4、AP5，对于数据自适应加权融合后，AP1、AP2、AP3、AP4、AP5 的权重系数见表 4.1 所示。

上述所选的 30 个样本，送入婴儿运动轨迹的功率谱特征训练出的模型进行测试，测试得到的对应左上肢、右上肢、左下肢、右下肢和全身整体的结果，分别命名为 GP1、GP2、GP3、GP4、GP5，对于数据自适应加权融合后，GP1、GP2、GP3、GP4、GP5 的权重系数见表 4.1 所示。

上述所选的 30 个样本，送入婴儿目标的质心变化特征训练出的模型进行测试，测试对应得到左上肢、右上肢、左下肢、右下肢和全身整体的结果，分别命名为 CP1、CP2、CP3、CP、CP5，对于数据自适应加权融合后，CP1、CP2、CP3、CP4、CP5 的权重系数见表 4.1 所示。

上述所选的 30 个样本，送入婴儿运动的速度特征训练出的模型进行测试，测试对应得到左上肢、右上肢、左下肢、右下肢和全身整体的结果，分别命名为 SP1、SP2、SP3、SP4、SP5，对于数据自适应加权融合后，SP1、SP2、SP3、SP4、SP5 的权重系数见表 4.1 所示。

上述所选的 30 个样本，送入婴儿运动的加速度特征训练出的模型进行测试，测试对应左上肢、右上肢、左下肢、右下肢和全身整体的结果，分别命名为 ACP1、ACP2、ACP3、

ACP4、ACP5, 对于数据自适应加权融合后, ACP1、ACP2、ACP3、ACP4、ACP5 的权重系数见表 4.1 所示。

表 4.1 各特征的权重系数

	左上肢	右上肢	左下肢	右下肢	全身
小波域	0.23272	0.19026	0.16029	0.20836	0.20836
功率谱域	0.15317	0.17631	0.12500	0.39212	0.15317
运动速度	0.19039	0.12185	0.19039	0.24868	0.24868
运动加速度	0.18248	0.11679	0.46715	0.11679	0.11679
质心变化	0.20137	0.12181	0.27408	0.20137	0.20137

对于婴儿运动轨迹提取的小波特征、婴儿运动轨迹提取的功率谱特征、婴儿运动的速度特征、婴儿运动的加速度特征以及婴儿运动的质心变化特征的最终判断结果, 只要将婴儿的左上肢、右上肢、左下肢、右下肢和全身这五部分的判断结果乘以相应的权重再相加即可得到。

而对于婴儿的质心个数这个特征来说, 根据图 4.9 婴儿质心个数比较来看, 异常婴儿样本的质心个数在一定程度上都要比正常样本质心个数要多, 但也存在容易混淆的部分。而对于婴儿质心个数这个特征的分析, 由于我们是对整个视频帧目标部分进行叠加再通过边缘算子等处理连通域的方法来统计其质心的个数, 是直接针对婴儿整体来看待的, 因此, 这里并不需要区分左上肢、右上肢、左下肢、右下肢及全身这五个部分, 所以没有权重系数, 直接利用支持向量机进行分类判断即可。

对于最终分类判断的结果, 本文使用如下指标进行判断, 定义真阳性 (TP): 行为异常婴儿判断为行为异常。假阳性 (FP): 行为正常的婴儿判断为行为异常。真阴性 (TN): 行为正常的婴儿判断为行为正常。假阴性 (FN): 行为异常的婴儿判断为行为正常。由此定义三个度量标准, 灵敏度 (SE), 特异性 (SP), 准确率 (AC), 其中:

$$SE = \frac{TP}{TP + FN} \dots\dots\dots (4.34)$$

$$SP = \frac{TN}{TN + FP} \dots\dots\dots (4.35)$$

$$AC = \frac{TP + TN}{TP + FN + TN + FP} \dots\dots\dots (4.36)$$

对于婴儿运动轨迹得到的小波特征、婴儿运动轨迹得到的功率谱特征、婴儿运动的速度特征、婴儿运动的加速度特征、婴儿运动的质心变化特征以及质心个数特征。虽然根据前文的分析其中一些特征如婴儿运动的速度特征, 婴儿运动的加速度特征以及婴儿的质心个数特征在区分行为正常的婴儿样本和行为异常的婴儿样本时所表现出的特异性并不高,

甚至很难区分,但为了验证该结论还是将这六组特征都送入分类器进行分类判断,分析各项指标情况。

婴儿运动轨迹得到的小波特征、婴儿运动轨迹得到的功率谱特征、婴儿运动的速度特征、婴儿运动的加速度特征、婴儿运动的质心变化特征以及质心个数特征这六组特征对于区分婴儿行为是否异常的特异度,灵敏度以及准确率,真阳性个数,假阴性个数,真阴性个数以及假阳性个数都如表 4.2 所示。

表 4.2 多组特征下婴儿异常行为判断指标

特征	灵敏度 (SE)	特异性 (SP)	准确率 (AC)	真阳性 TP/假阴性 FN/真阴性 TN/假阳性 FP
小波域	(83.3±8.6)%	(78.3±3.3)%	(80.8±5.9)%	12.50±1.29/2.50±1.29 11.75±0.50/3.25±0.50
功率谱域	(93.3±6.6)%	(85.0±10.0)%	(89.2±8.3)%	14.00±1.00/1.00±1.00 12.75±1.50/2.25±1.50
运动速度	(50.0±8.0)%	(70.0±4.7)%	(60.0±6.3)%	7.50±1.20/7.50±1.20 10.50±0.70/4.50±0.70
运动加速度	(90.0±9.7)%	(50.0±3.3)%	(70.0±6.5)%	13.50±1.45/1.50±1.45 7.50±0.50/7.50±0.50
质心变化	(90.0±6.7)%	(60.0±8.7)%	(75.0±8.0)%	13.50±1.00/1.50±1.00 9.00±1.30/6.00±1.30
质心个数	(98.0±0.6)%	(28.3±3.4)%	(63.2±2.0)%	14.70±0.10/0.30±0.10 4.25±0.50/10.75±0.50
多特征融合	(95.0±5.0)%	(91.7±6.3)%	(93.3±5.7)%	14.25±0.75/0.75±0.75 13.75±0.95/1.25±0.95

结合 4.2.2 节的特征分析结果和表 4.2 多组特征在实际分类中的各项指标情况显示,婴儿运动的速度特征,婴儿运动的加速度特征以及婴儿的质心个数特征这三组特征都不能很好的进行分类。

其中婴儿运动的速度特征,不论是从灵敏度,特异性,还是准确率来说,指标都在 50%左右徘徊,其中灵敏度为(50.0±8.0)%,特异性为(70.0±4.7)%,准确率为(60.0±6.3)%说明该特征不能很好的区分婴儿行为的正常与否,不能用作分类指标。婴儿运动的加速度特征,特异性指标很低为(50.0±3.3)%,而灵敏度又很高为(90.0±9.7)%,说明将行为正常的婴儿误判为行为异常的婴儿的概率很高,同样没有形成很好的分类结果,婴儿运动的加速度特征容易将正常的都归类为异常,无法对正常和异常婴儿进行区分。对于婴儿的质心个数这一特征,它的灵敏度接近 100%,而特异性只有 20%左右,同样属于是将几乎所有样本都归类为了异常样本,完全没有形成区分,该特征会把行为正常的婴儿样本大都归类为行为异常的婴儿样本,是以该特征也无法作为分类的特征。

因此本文最后选择的特征为婴儿运动轨迹的小波特征,婴儿运动轨迹的功率谱特征以及婴儿的质心变化特征,而最终的融合结果判断是,如果这三个特征中的大于等于两个特征判定婴儿行为为异常,即最终结论为婴儿行为异常,反之,则判定婴儿行为为正常。最终的结果见表 4.2 最后一行所示。结合最终的特征选择,本文提出的基于多特征融合的婴儿异常行为检测框架流程图如图 4.13 所示。根据本文提出的基于多特征融合的婴儿异常行为检测框架,对于待测得婴儿视频,送入检测系统进行婴儿行为异常与否的判断,最终在特异性,灵敏度以及准确率这三方面都取得了不错的结果。

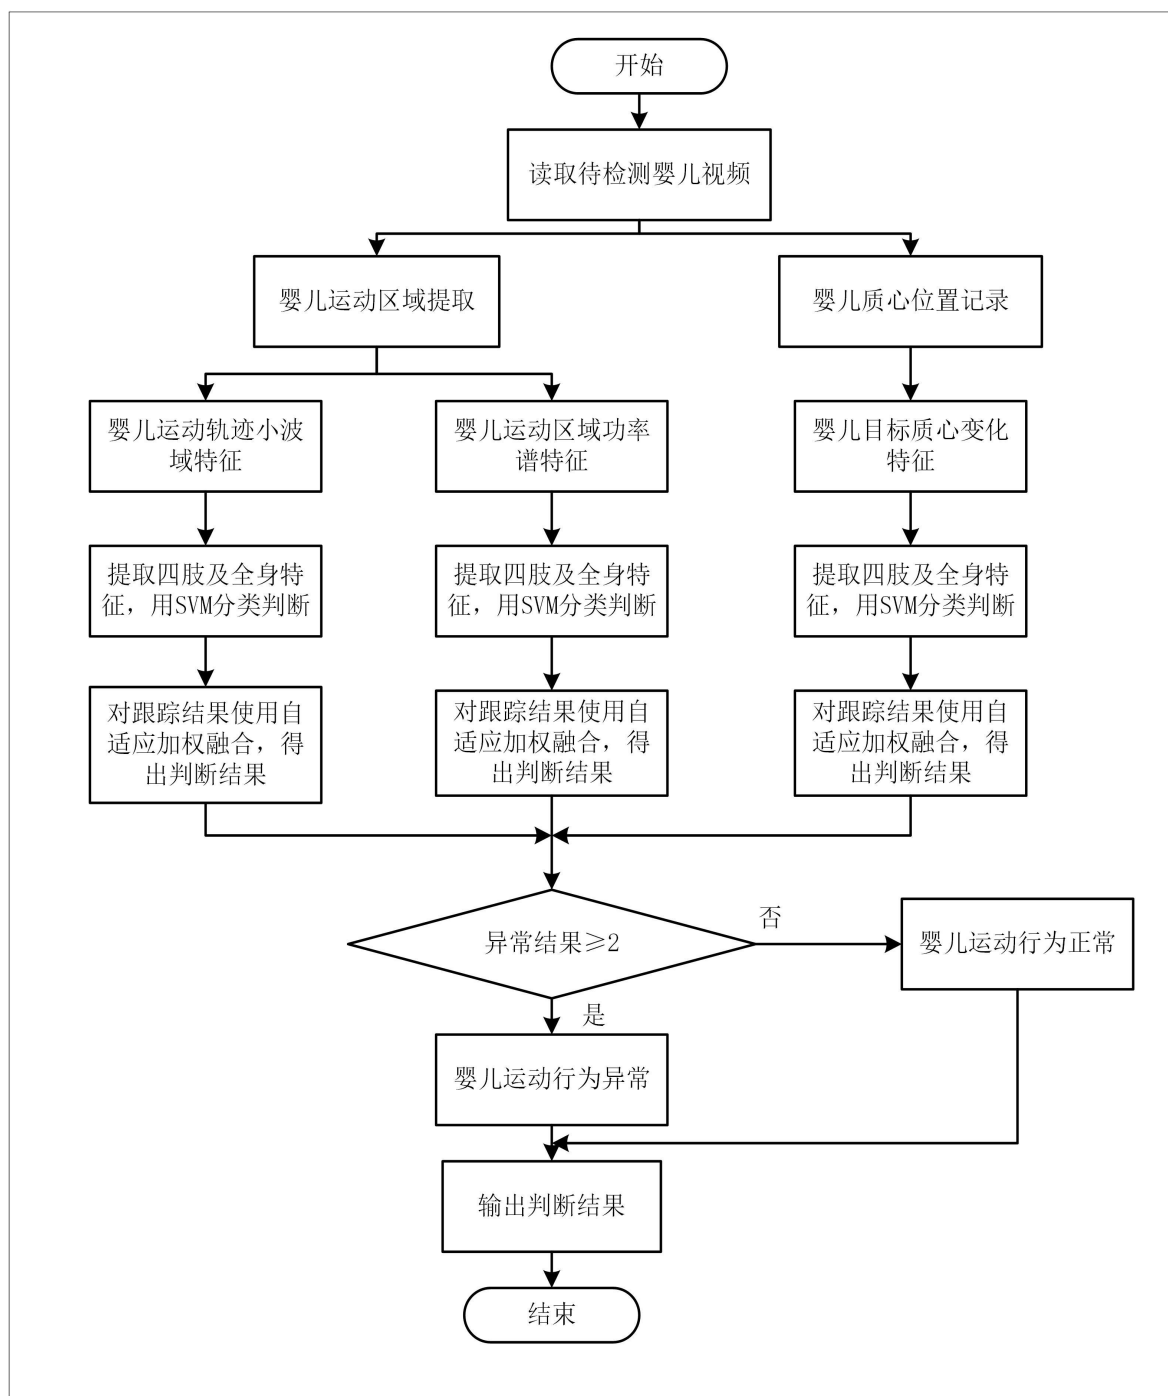


图 4.13 基于多特征融合的婴儿异常行为检测流程图

4.4 本章小结

本章提出了一种基于多特征融合的婴儿异常行为检测框架。在本章的开头首先对第3章得到的婴儿运动轨迹的小波域特征，婴儿运动轨迹的功率谱域特征，婴儿运动的速度特征，婴儿运动的加速度特征，婴儿的质心变化特征以及婴儿的质心个数特征分别进行了特征分析。在特征分析阶段，在提取婴儿运动轨迹提取的小波域特征，婴儿运动轨迹提取的功率谱域特征时，特征都表现出了明显的特异性，而对于婴儿运动的速度特征，婴儿运动的加速度特征，婴儿的质心个数特征，婴儿的质心变化特征又进行了进一步分析。对维数太高而样本数又不足的特征进行了降维处理，并分别送入分类器进行行为异常与否的分类，对这六组特征分别进行了定量分析，通过自适应的融合方法对结果进行分析得出关于婴儿神经发育是否异常的各项判断指标。经分析最终选定婴儿运动轨迹的小波域特征，婴儿运动轨迹的功率谱特征以及婴儿的质心变化特征作为最后的特征组合，最终得出婴儿行为是否异常的结论。

第5章 总结与展望

5.1 研究总结

婴儿早期神经发育异常往往伴随着全身异常运动。对于婴儿异常运动的判断，可以起到及早发现婴儿神经发育是否异常，从而对其进行早期干预。婴儿的异常行为对应着脑部有损伤，严重者可能导致脑瘫的发生，由于脑瘫疾病通常在孩子一岁至两岁后才能确诊，因此，研究早期婴儿异常行为检测并及时进行干预治疗有很强的现实意义。

在了解一定关于产生婴儿异常运动的医学背景情况下，结合婴儿在行为上表现出的特征，本文以提出一种基于多特征融合的婴儿异常行为检测框架为目标，将医学上的对于行为异常的婴儿判断，通过结合计算机视觉以及机器学习等知识，进行了一系列的研究，实现代替人工判断的最终结果，本文的研究工作主要有如下几个方面：

(1) 在对婴儿进行目标跟踪识别的时候，由于目标背景单一且不要求实时，选择较为简单的目标跟踪算法，即 Meanshift 算子，在分析该算子的原理及特点后发现，该算子算法简单，但是依据的判断条件单一，为此提出基于注意力机制的婴儿目标跟踪方法，弥补 Meanshift 算子存在的一些缺陷，并在婴儿样本的跟踪上取得了不错的跟踪效果。

(2) 对于婴儿特征的提取，分别就基于婴儿的运动轨迹分析和基于婴儿本身人体的物理特征的分析两方面，在考虑运动信号变化的前提下提取了基于婴儿运动轨迹的小波域特征信息，在考虑时频域对应的信号特性的前提下提取了基于运动轨迹的功率谱特征信息，在考虑婴儿运动过程中四肢运动的速度变化时提取了婴儿运动的速度特征信息，婴儿运动的加速度特征信息，以及婴儿的质心变化特征，在考虑基于人体特征情况下提取了婴儿质心数量特征，分别对这几组特征的正常和异常样本进行了分析和比较，并且分别建立了对应的特征样本库。

(3) 本文提出基于多特征融合的婴儿异常行为检测框架，从对婴儿目标进行跟踪，到多组特征的提取分析，对于多种特征进行自适应的融合判断，最后得出婴儿运动是否异常的结论。其中对于婴儿的检测过程中，不同于往常将婴儿看作一个整体直接进行研究，而是将婴儿分成婴儿的左上肢、右上肢、左下肢、右下肢以及全身五个部分。分别对这五个部分进行特征提取和分类，最后综合判断。对婴儿身体躯干分块判断，提高了对婴儿身体各个部位的灵敏度和特异度，也对最后的综合判断给出了更强有力的数据支撑。

5.2 研究展望

本文的研究是基于婴儿样本来进行的，由于隐私原因以及对于婴儿早期行为检测的普适性不高，导致样本的数量较少，从而在建模的过程中会存在一些问题。在综合的研究过

程中，本人认为还有可以深入讨论和研究的内容如下：

（1）由于医学样本数量较少，对于少量样本如何提取出更多的信息是一个有待进一步深入研究的方面。在样本中可提取充足信息的情况下，可以用来作为对比的特征以及蕴含在样本本身的一些运动规律都可以得到更好的研究。同时，如果提取到的信息样本足够多的，选用现如今热门的深度学习方法进行分类判断等一系列操作，可能能够取得更高的准确率和更好的判断效果。例如现在深度学习中的小样本学习等，可以做为一个不错的研究切入点。

（2）对于婴儿行为的判断，可作为分类依据的特征种类有很多，根据所研究的侧重点不同，能够提取的特征也有所不同。本文根据基于运动轨迹的小波特征信息，基于运动轨迹的功率谱特征信息，婴儿运动的速度特征信息，婴儿运动的加速度特征信息，以及婴儿的质心变化特征和质心数量特征，分别建立样本库。但同时也可考虑其他方向如何提取特征，利用不同思考维度提取多元化的特征，更加全面具有说服力的对婴儿行为异常与否进行判断。

参考文献

- [1] PRECHTL H F R, FERRARI F, CIONI G. Predictive value of general movements in asphyxiated fullterm infants[J]. Early Human Development, 1993, 35(2): 91–120.
- [2] 陈鸣, 杨红, 侯方华, 史惟, 邹婧, 曹云, 王艺, 朱晓芸, 骆丹丹, 朱默, 邵肖梅. 全身运动评估对极低出生体重早产儿运动发育结局的预测价值[J]. 中国儿童保健杂志, 2012, 20(12): 1067-1069, 1073.
- [3] 杨红. 全身运动 (GMs) 评估在高危儿运动发育随访中的应用研究[D]. 上海: 复旦大学, 2009.
- [4] 马良, 孟令丹, 王宝宏, 等. 早期干预对早产儿不安运动阶段全身运动质量的影响[J]. 中国康复理论与实践, 2014, (12): 1147–1149.
- [5] MEINECKE L, BREITBACH-FALLER N, BARTZ C, et al. Movement analysis in the early detection of newborns at risk for developing spasticity due to infantile cerebral palsy[J]. Human Movement Science, 2005, 25(2): 125–144.
- [6] ADDE L, HELBOSTAD, JORUNN L, JENSENIUS A R, et al. Early prediction of cerebral palsy by computer-based video analysis of general movements: a feasibility study[J]. Developmental Medicine & Child Neurology, 2010, 52(8): 773–778.
- [7] STAHL A, SCHELLEWALD C, STAVDAHL O, et al. An Optical Flow-Based Method to Predict Infantile Cerebral Palsy[J]. IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2012, 20(4): 605–614.
- [8] ADDE L, HELBOSTAD J L, JENSENIUS A R, et al. Using computer-based video analysis in the study of fidgety movements[J]. Early Human Development, 2009, 85(9): 541–547.
- [9] 高翔. 视频监控中行人异常行为分析研究[D]. 四川: 电子科技大学, 2018.
- [10] ADU J, GAN J, WANG Y, et al. Image fusion based on nonsubsampling contourlet transform for infrared and visible light image[J]. Infrared Physics & Technology, 2013, 61: 94–100.
- [11] HENRIQUES J, CASEIRO R, MARTINS P, et al. High-Speed Tracking with Kernelized Correlation Filters - IEEE Journals & Magazine[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2015, 37: 583–596.
- [12] RAHMATI H, MARTENS H, AAMO O, et al. Frequency Analysis and Feature Reduction Method for Prediction of Cerebral Palsy in Young Infants - IEEE Journals & Magazine[J].

- IEEE Transactions on Neural Systems and Rehabilitation Engineering, 2016, 24: 1225–1234.
- [13] FJØRTOFT T, EINSPIELER C, ADDE L, et al. Inter-observer reliability of the “Assessment of Motor Repertoire — 3 to 5 Months” based on video recordings of infants[J]. Early Human Development, 2009, 85(5): 297–302.
- [14] ADDE L, THOMAS N, JOHN H, et al. Early motor repertoire in very low birth weight infants in India is associated with motor development at one year[J]. European Journal of Paediatric Neurology, NTNU, 2016, 20: 918–924.
- [15] VALLE S C, STØEN R, SÆTHER R, et al. Test–retest reliability of computer-based video analysis of general movements in healthy term-born infants[J]. Early Human Development, 2015, 91(10): 555–558.
- [16] YUE T, SUO J, CAO X, et al. Efficient Method for High-Quality Removal of Nonuniform Blur in the Wavelet Domain[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2017, 27(9): 1869–1881.
- [17] CHAI Y, LI H, ZHANG X. Multifocus image fusion based on features contrast of multiscale products in nonsubsamped contourlet transform domain[J]. Optik, 2012, 123(7): 569–581.
- [18] DO M N, VETTERLI M. The contourlet transform: an efficient directional multiresolution image representation[J]. IEEE Transactions on Image Processing, 2005, 14(12): 2091–2106.
- [19] UIJLINGS J R R, VAN DE SANDE K E A, GEVERS T, et al. Selective Search for Object Recognition[J]. International Journal of Computer Vision, 2013, 104(2): 154–171.
- [20] DICKINSON P, HUNTER A, APPIAH K. A spatially distributed model for foreground segmentation[J]. Image and Vision Computing, 2009, 27(9): 1326–1335.
- [21] CAI N, ZHU N, GUO W, et al. Object Tracking Using Mean Shift for Adaptive Weighted-Sum Histograms[J]. Circuits, Systems, and Signal Processing, 2014, 33(2): 483–499.
- [22] PATEL M, LAL S, KAVANAGH D, et al. Fatigue Detection Using Computer Vision[J]. International Journal of Electronics and Telecommunications, 2010, 56(4): 457–461.
- [23] KUEN J, LIM K M, LEE C P. Self-taught learning of a deep invariant representation for visual tracking via temporal slowness principle[J]. Pattern Recognition, 2015, 48(10): 2964–2982.

- [24]LIN B, WEI X, JUNJIE Z. Automatic recognition and classification of multi-channel microseismic waveform based on DCNN and SVM[J]. Computers & Geosciences, 2019, 123: 111–120.
- [25]OJALA T, PIETIKÄINEN M, HARWOOD D. A comparative study of texture measures with classification based on featured distributions[J]. Pattern Recognition, 1996, 29(1): 51–59.
- [26]AFIFI S, GHOLAMHOSSEINI H, SINHA R. A system on chip for melanoma detection using FPGA-based SVM classifier[J]. Microprocessors and Microsystems, 2019, 65: 57–68.
- [27]ZOU B, TANG Y Y, XU Z, et al. The generalization performance of regularized regression algorithms based on Markov sampling[J]. IEEE transactions on cybernetics, United States: 2014, 44(9): 1497–1507.
- [28]XU J, YAN TANG Y, ZOU B, et al. The generalization ability of online SVM classification based on Markov sampling[J]. IEEE transactions on neural networks and learning systems, United States: 2015, 26(3): 628–639.
- [29]XIAO J. SVM and KNN ensemble learning for traffic incident detection[J]. Physica A: Statistical Mechanics and its Applications, 2019, 517: 29–35.
- [30]NANA Z, JIN Z. Optimization of Face Tracking Based on KCF and Camshift[J]. Procedia Computer Science, 2018, 131: 158–166.
- [31]NEDJAR I, DAHO M ., SETTOUTI N, et al. RANDOMFOREST BASED CLASSIFICATION OF MEDICAL X-RAY IMAGES USING A GENETIC ALGORITHM FOR FEATURE SELECTION[J]. Journal of Mechanics in Medicine and Biology, Journal of Mechanics in Medicine and Biology, 2013, 15(2).
- [32]FERN A, SCHAPIRE R. Online Ensemble Learning: An Empirical Study[J]. Machine Learning, 2003, 53(1–2): 71–109.
- [33]MAO S, CHEN J-W, JIAO L, et al. Maximizing diversity by transformed ensemble learning[J]. Applied Soft Computing, 2019, 82: 105580.
- [34]姜丹. 基于视频监控的目标检测与跟踪算法研究[D].西安理工大学,2018.
- [35]朱文青,刘艳,卞乐,张子龙.基于生成式模型的目标跟踪方法综述[J].微处理机,2017,38(01):41-47.
- [36]王小峰,王吉华,王远鹏,张晓伟.混合高斯模型和差分法相融合的运动目标检测[J].小型微型计算机系统,2013,34(03):685-688.

- [37]王静静,林明秀,魏颖.基于灰度相关的帧间差分和背景差分相融合的实时目标检测[J].中南大学学报(自然科学版),2009,40(S1):142-148.
- [38]吕学斌,周群彪,陈正茂,赵明华.一种改进粒子滤波器在雷达目标跟踪中的应用[J].系统仿真学报,2007(09):2097-2100.
- [39]夏东.智能视频监控中目标检测、跟踪和识别方法研究[D].国防科学技术大学,2012.
- [40]王欢.复杂场景下的运动目标检测与跟踪研究[D].北京理工大学,2015.
- [41]周越,张帆,夏彩凤.一种基于改进型 meanshift 算法的运动目标跟踪方法[J].科技经济导刊,2017(21):184.
- [42]王相海,刘美瑶,苏元贺,方玲玲,宋传鸣.基于 Contourlet 和 MeanShift 的交通视频车辆跟踪算法[J].辽宁师范大学学报(自然科学版),2017,40(02):192-198.
- [43]杜静雯,黄山,杨双祥.自适应 HLBP 纹理特征的 Meanshift 目标跟踪算法[J].计算机科学,2017,44(S2):217-220.
- [44]史宝明,贺元香,邢玉娟.融合边缘特征的 MeanShift 跟踪算法[J].兰州文理学院学报(自然科学版),2015,29(06):48-52.
- [45]席志红,李永佳,段炼.基于局部特征和 MeanShift 的目标跟踪算法研究[J].电子科技,2015,28(06):13-16.
- [46]师哲.视频监控下实时异常行为检测研究[D].江苏:南京邮电大学,2017.
- [47]陆平,邓硕,李伟华.基于深度学习的多目标跟踪算法研究[J].中兴通讯技术,2017,23(04):14-19.
- [48]郑胤,陈权崎,章毓晋.深度学习及其在目标和行为识别中的新进展[J].中国图象图形学报,2014,19(02):175-184.
- [49]杨燕平.基于深度学习的手势跟踪方法研究[D].电子科技大学,2018.
- [50]杜静雯,黄山.尺度自适应的 HLBP 纹理特征目标跟踪算法[J].计算机工程与设计,2018,39(07):1889-1894+1929.
- [51]陈菲,黄勇坚,李淑彦,张舟.自适应窗口的 meanshift 目标跟踪算法[J].电子技术,2016,45(05):1-4.
- [52]李康,李亚敏,胡学敏,邵芳.基于卷积神经网络的鲁棒高精度目标跟踪算法[J].电子学报,2018,46(09):2087-2093.
- [53]杨德红,闫河,刘婕,王朴.HLBP 纹理特征 Mean Shift 目标跟踪算法[J].计算机工程与设计,2016,37(04):976-981.

- [54]任世锦,吴铁军.基于径向基小波核的多尺度小波支持向量机[J].电路与系统学报,2008(04):70-76+80.
- [55]林继鹏,刘君华.基于小波的支持向量机算法研究[J].西安交通大学学报,2005(08):816-819.
- [56]王雯.应用 Contourlet 变换的目标跟踪算法研究[D].兰州理工大学,2016.
- [57]郭文婷,蔡念.基于 Contourlet 直方图的目标跟踪算法[J].激光与红外,2012,42(10):1177-1180.
- [58]王飞,魏国亮,王保云,邹国燕.基于分块的核窗宽调整 mean-shift 跟踪算法[J].光电工程,2014,41(04):41-46+53.
- [59]赵琳,王秋帆,刘源,郝勇.基于 HASH 感知和小波变换的目标跟踪算法[J].系统工程与电子技术,2016,38(04):739-745.
- [60]李宁,贾飞勇,杜琳.全身运动质量评估:超早期预测早产儿神经发育结局的可靠工具[J].中国当代儿科杂志,2013,15(04):317-321.
- [61]陈强,唐宇轩,张德祥.全身运动质量评估技术在高危儿随访中的临床应用价值[J].中国卫生标准管理,2015,(15):17-17.

作者简介及科研成果

作者简介：

戴晓辉，女，1995 年出生于内蒙古自治区乌兰察布市，2017 年 6 月本科毕业于吉林大学，通信工程学院，信息工程专业，研究生就读于吉林大学，通信工程学院，信号与信息处理专业，研究方向为计算机视觉图像处理。

攻读硕士期间的科研成果：

[1] Dai Xiaohui, Wang Shigang, Li Honghua, Yue Haichun, Min Jiayuan. Image-Assisted Discrimination Method for Neurodevelopmental Disorders in Infants Based on Multi-feature Fusion and Ensemble Learning [C]. Brain Informatics - 12th International Conference(BI 2019), Lecture Notes in Computer Science, ,11976:105-114, Haikou,China,2019.

This paper is honored with Best Paper Nomination Award.

[2] 王世刚，戴晓辉，赵岩，韦健. 基于条件生成对抗网络和 SVM 的婴儿异常行为检测方法，发明专利，申请公开日期: 2019.04.16, 中国, 201811494749.0.

致 谢

时间如白驹过隙，一转眼研究生三年的学习生涯转瞬即逝，回想起来，仿佛刚刚进入这个实验室，进入这个科研小组还是昨天的事情，制定的第一份计划，学习的第一个算法，都好像还近在眼前。回顾这三年的研究生学习历程，有欢笑，有泪水，有开心，有沮丧，但更多的是获得每一次进步的成就感和自豪感，在此，要特别感谢这一路走来对我影响很深的老师，亲人，朋友们。感谢你们！

首先，我要感谢我的导师王世刚教授，是在您的指导和鼓励下，我才能有今天的成绩。王老师为人和蔼又不失威严，对我们的指导从来不是苛责逼迫，永远都是循循善诱，并且经常和我们分享研究领域的前沿动态，潜移默化中培养我们的科研兴趣。而在进行学术讨论时，王老师又是严肃的，专业的，对我科研中产生的问题，往往点评的一针见血，可以说是在王老师的指导和影响下，让我对图像处理，计算机视觉产生了浓厚的兴趣。同时在学习上，王老师也特别关心我们，会在我们科研的身心疲惫时举办一些趣味性的活动，拉近了实验室师生的距离。王老师对待科研的严谨专业，对待生活的热情活力，让我受益颇多，在这里要说一声：王老师，您辛苦了！

其次要感谢我的父母亲人，你们做为我的坚强后盾，一直鼓励我给我信心和力量，是我在人生旅途上走累了了的驿站，也是我遇到挫折困难的避风港湾，因为有你们的支持和鼓励，我在能在人生这条道路上勇往直前，无所畏惧，所向披靡，感谢你们，在未来的日子里请让我成为你们的驿站，你们的港湾。感谢我远在家乡的小伙伴们，是你们不论我快乐或是沮丧，都站在我这一边鼓励我，与我分享喜悦，为我加油打气。

还要感谢我的室友们，无论遇到快乐的事，难过的事，总是会第一时间和你们分享，我们总是彼此激励，在科研之余一起去放松，你们是我获取正能量的源泉。感谢我的实验室小伙伴们，感谢我的师兄师姐们在我科研最初刚入门时对我的关照和指导，你们总是耐心的解答我的问题，在生活中也很热心的关心帮助我，让我从一个所谓的萌新逐渐成长为一个合格的研究生；感谢和我同届的小伙伴，作为同一届，我们总是有很多共同的话题，会遇到共同的问题，在这个时候，是你们让我知道我不是一个人，让我体会到团结体会到集体的力量；感谢我的师弟师妹们，感谢你们对我的信任，也感谢你们总是会在科研之余给我带来欢声笑语。希望研究生三年遇到的所有朋友都能够前程似锦，不忘初心。

最后，感谢审阅论文和参与答辩的老师，谢谢你们，你们辛苦了！